



UTA

UNIVERSIDADE TÉCNICA
DO ATLÂNTICO

UNIVERSIDADE TÉCNICA DO ATLÂNTICO

INSTITUTO DE ENGENHARIAS E CIÊNCIAS DO MAR

Departamento de Engenharia Eletrotécnica Informática e Telecomunicações

Licenciatura em Engenharia Informática e Telecomunicações

DeepCoin: Um Estudo Comparativo de Algoritmos de Machine Learning para Previsão de Criptomoedas

Aluno | Rodrigo Hendrick Monteiro Santos Fortes

Orientador | Prof. Doutor Estanislau Lima

Coorientador | Mestre Roberto Carlos Medina

Mindelo

Ano Letivo 2025/2026



UNIVERSIDADE TÉCNICA DO ATLÂNTICO

INSTITUTO DE ENGENHARIAS E CIÊNCIAS DO MAR

Departamento de Engenharia Eletrotécnica Informática e Telecomunicações

Licenciatura em Engenharia Informática e Telecomunicações

DeepCoin: Um Estudo Comparativo de Algoritmos de Machine Learning para Previsão de Criptomoedas

Aluno | **Rodrigo Hendrick Monteiro Santos Fortes**

Orientador | Prof. Doutor Estanislau Lima

Coorientador | Mestre Roberto Carlos Medina

Mindelo

Ano Letivo 2025/2026



UNIVERSIDADE TÉCNICA DO ATLÂNTICO

INSTITUTO DE ENGENHARIAS E CIÊNCIAS DO MAR

Departamento de Engenharia Eletrotécnica Informática e Telecomunicações

Licenciatura em Engenharia Informática e Telecomunicações

DeepCoin: Um Estudo Comparativo de Algoritmos de Machine Learning para Previsão de Criptomoedas

Trabalho de Fim de Curso apresentado como requisito para obtenção do título de **Licenciado em Engenharia Informática e de Telecomunicações** no Instituto de Engenharias e Ciências do Mar da Universidade Técnica do Atlântico.

Aluno

Orientador

Coorientador

Rodrigo Hendrick
Monteiro Santos Fortes

Prof. Doutor Estanislau
Lima

Mestre Roberto Carlos
Medina

Mindelo

Ano Letivo 2025/2026

Agradecimentos

Ao recordar o momento em que encarei os desafios da Engenharia, lembro-me do medo, da curiosidade e da responsabilidade que me moldaram. Ser engenheiro é mediar ideias e matéria; esta caminhada está apenas a começar e muito do que conquistei deve-se ao apoio de pessoas que compartilharam comigo força e esperança.

Em primeiro lugar, agradeço à minha família — em especial aos meus pais, Raquel Monteiro e César Santos Fortes, e aos meus sete irmãos — pelo apoio incondicional, pelas palavras de incentivo e pela confiança constante no meu potencial. O vosso amparo foi a base sobre a qual construí este percurso académico.

Ao meu pai, agradeço de forma especial pela orientação e pelos ensinamentos que me prepararam para os desafios desta nova etapa.

Aos meus orientadores, Professor Estanislau Lima e Roberto Medina, expresso a minha profunda gratidão pela paciência, pela orientação científica e pelo incentivo profissional, essenciais para a concretização deste trabalho.

À Universidade Técnica do Atlântico sou grato pelas oportunidades de formação e pelos recursos disponibilizados, que possibilitaram um ambiente para o meu desenvolvimento. Agradeço igualmente à minha turma de LEIT — 4.º Ano (2024–2025) pelo companheirismo, pela colaboração e pelo espírito de equipa demonstrado ao longo destes anos.

À minha namorada, agradeço profundamente pela paciência, compreensão e apoio emocional. Obrigado por nunca deixares de acreditar em mim — nos momentos de crise e nos de prosperidade — e por seres uma presença constante que me inspira a ir mais longe.

Por fim, agradeço a mim mesmo pela disciplina, resiliência e determinação que mantive ao longo desta caminhada. Agradeço também aos meus amigos — ainda que não os consiga mencionar individualmente — por cada palavra, gesto e presença que contribuíram para esta fase da minha vida académica.

Resumo

Atualmente, as criptomoedas consolidaram-se como sistemas descentralizados de transferência de valor, nos quais a confiança tradicional é substituída pela criptografia e pelos algoritmos. A volatilidade destes ativos, influenciada por fatores económicos, políticos e globais, torna a previsão dos seus preços um desafio significativo e de elevada complexidade. Este trabalho investiga a aplicação de técnicas avançadas de Inteligência Artificial (IA), nomeadamente *Machine Learning* (ML) e *Deep Learning* (DL), na previsão dos preços de Bitcoin, Ethereum e Solana, com foco na análise temporal e no apoio à tomada de decisão. O estudo compara a eficiência dos modelos DL - LSTM, GRU, TCN e Transformer - com os métodos tradicionais, como o Random Forest. A avaliação incluiu análises de desempenho - RMSE, MAE, MAPE e R^2 - e cenários com e sem *data augmentation*, permitindo identificar os modelos mais adequados para diferentes conjuntos de dados. Os resultados mostram a consistência dos modelos testados, destacando-se o TCN, que apresentou um melhor desempenho global e superou o *Random Forest* no *dataset* da Bitcoin após *data augmentation*.

Palavras-chave: Criptomoedas, Previsão de Preços, Machine Learning, Deep Learning, Data Augmentation

Abstract

Currently, cryptocurrencies have become established as decentralized value transfer systems, in which traditional trust is replaced by cryptography and algorithms. The volatility of these assets, influenced by economic, political, and global factors, makes predicting their prices a significant and highly complex challenge. This work investigates the application of advanced Artificial Intelligence (AI) techniques, namely Machine Learning (ML) and Deep Learning (DL), in predicting the prices of Bitcoin, Ethereum, and Solana, focusing on temporal analysis and decision support. The study compares the efficiency of DL models – LSTM, GRU, TCN, and Transformer – with traditional methods such as Random Forest. The evaluation included performance analyses – RMSE, MAE, MAPE, and R^2 – and scenarios with and without data augmentation, allowing the identification of the most suitable models for different datasets. The results show the consistency of the tested models, with TCN standing out as it presented the best overall performance and outperformed Random Forest in the Bitcoin dataset after data augmentation.

Keywords: Cryptocurrencies, Price Prediction, Machine Learning, Deep Learning, Data Augmentation

Lista de Figuras

Figura 1: Linha Temporal da evolução das moedas digitais	6
Figura 2: Estrutura de <i>blockchain</i> , composta por uma cadeia contínua de blocos in- terligados	9
Figura 3: Relação hierárquica entre IA, ML, DL e LLM	12
Figura 4: Processo de construção do modelo <i>Random Forest</i>	14
Figura 5: Célula LSTM segundo Hochreiter e Schmidhuber (1997)	15
Figura 6: Arquitetura interna da célula GRU	17
Figura 7: Arquitetura da TCN com fatores de dilatação crescente ($d = 1, 2, 4$)	18
Figura 8: Arquitetura do modelo Transformer baseado no mecanismo de atenção . .	19
Figura 9: Exemplo de aplicação da técnica de jittering em séries temporais financeiras	23
Figura 10: Representação do ciclo de desenvolvimento da metodologia	31
Figura 11: Features normalizadas da base de treino do Bitcoin, com procedimento equivalente para Ethereum e Solana.	36
Figura 12: Coluna <i>Close</i> com <i>Jittering</i> e <i>Drift</i>	38
Figura 13: Interface de Previsão de Preços de Criptomoedas.	44
Figura 14: Interface de Previsão de Preços de Criptomoedas.	45
Figura 15: Comparação entre valores reais e previsões do modelo Random Forest para Solana, Bitcoin e Ethereum.	47
Figura 16: Comparação dos gráficos de Loss de treinamento e validação dos modelos no dataset Bitcoin, antes e depois da aplicação de data augmentation. . . .	49
Figura 17: Comparação dos gráficos de Loss de treinamento e validação dos modelos no dataset Ethereum, antes e depois da aplicação de data augmentation. . .	51
Figura 18: Comparação dos gráficos de Loss de treinamento e validação dos modelos no dataset Ethereum, antes e depois da aplicação de data augmentation. . .	53

Lista de Tabelas

Tabela 1: Top Criptoativos por Capitalização e Caso de Uso	7
Tabela 2: Síntese comparativa de estudos relacionados à previsão de preços de criptomoedas	27
Tabela 3: Especificações de Hardware e Sistema Operativo	29
Tabela 4: Principais Bibliotecas de Software Utilizadas	30
Tabela 5: Características dos Datasets das Criptomoedas	33
Tabela 6: Descrição das Variáveis OHLCV	33
Tabela 7: Amostra de Registos da Base de Dados de Solana (Yahoo Finance)	34
Tabela 8: Número de Amostras dos Datasets das Criptomoedas antes e após Data Augmentation	37
Tabela 9: Estrutura das Arquiteturas dos Modelos de Previsão de Preços de Criptomoedas	39
Tabela 10: Hiperparâmetros de Treinamento dos Modelos de <i>Deep Learning</i>	40
Tabela 11: Desempenho do modelo Random Forest para Solana, Ethereum e Bitcoin (dados de teste).	46
Tabela 12: Desempenho dos modelos preditivos para Bitcoin, com e sem Data Augmentation.	50
Tabela 13: Desempenho dos modelos preditivos para Ethereum, com e sem Data Augmentation.	52
Tabela 14: Desempenho dos modelos preditivos para Solana, com e sem Data Augmentation.	54

Abreviaturas

DL	Deep Learning
EVM	Ethereum Virtual Machine
GRU	Gated Recurrent Unit
IA	Inteligência Artificial
LLM	Large Language Model
LSTM	Long Short Term Memory
MAE	Mean Absolute Error
MAPE	Mean Absolute Percentage Error
R²	Coefficiente de Determinação
ML	Machine Learning
RF	Random Forest
RMSE	Root Mean Square Error
TCN	Temporal Convolutional Network

Conteúdo

Agradecimentos	I
Resumo	II
Abstract	III
Lista de Figuras	IV
Lista de Tabelas	V
Abreviaturas	VI
1 Introdução	1
1.1 Objetivos	2
1.1.1 Objetivo Geral	2
1.1.2 Objetivos Específicos	3
1.2 Estrutura do Trabalho	3
2 Fundamentação Teórica	5
2.1 Criptomoedas e Mercado Digital	5
2.1.1 Evolução Histórica das Moedas Digitais	5
2.1.2 Tipos de Criptomoedas	7
2.1.3 Tecnologia <i>Blockchain</i>	8
2.2 Inteligência Artificial	10
2.2.1 Modelos de <i>Machine Learning</i>	12
2.2.1.1 Random Forest	13
2.2.2 Modelos de Deep Learning	14
2.2.2.1 Long Short-Term Memory	15
2.2.2.2 Gated Recurrent Unit	16

2.2.2.3	Temporal Convolutional Network	17
2.2.2.4	Transformer	18
2.3	Técnicas de <i>Data Augmentation</i>	21
2.3.1	Jittering	22
2.3.2	Magnitude Warping	23
2.4	Trabalhos Relacionados	24
3	Materiais e Métodos	28
3.1	Materiais de Desenvolvimento	28
3.1.1	Especificações de Hardware	28
3.1.2	Especificações de Software	29
3.2	Metodologia de Pesquisa e Etapas de Implementação	30
3.3	Recolha e Análise dos Dados	32
3.4	Pré-Processamento	34
3.4.1	Limpeza e Divisão dos Dados	34
3.4.2	Normalização dos Dados	35
3.5	Aplicação do Data Augmentation	36
3.6	Detalhes de Treinamento dos Modelos	39
3.6.1	Arquitetura dos Modelos	39
3.6.2	Hiperparâmetros de Treinamento	40
3.7	Métricas de Avaliação dos Modelos	40
3.7.1	Erro Médio Absoluto (MAE)	41
3.7.2	Erro Percentual Absoluto Médio (MAPE)	41
3.7.3	Raiz do Erro Quadrático Médio (RMSE)	42
3.7.4	Coefficiente de Determinação (R^2)	42
3.8	Interface Gráfica	43
4	Resultados e Discussões	46
4.1	Resultados do Modelo: Random Forest	46
4.2	Resultados dos Modelos de Deep Learning	48

4.2.1	Resultados do Treinamento dos Modelos no Dataset Bitcoin	48
4.2.2	Resultados do Treinamento dos Modelos no Dataset Ethereum	50
4.2.3	Resultados do Treinamento dos Modelos no Dataset Solana	52
5	Discussões	54
6	Conclusão	57
6.1	Trabalhos futuros	57
	Referências	59

1 Introdução

Com a modernização tecnológica, as criptomoedas surgiram como ativos digitais descentralizados que dispensam intermediários financeiros, substituindo a confiança institucional por mecanismos criptográficos e protocolos de consenso distribuído. O aumento expressivo da sua adoção global tem sido impulsionado por avanços tecnológicos, pela facilidade de transferência internacional de fundos, pelo potencial de valorização e, simultaneamente, pela crescente desconfiança em relação às moedas tradicionais em um contexto de instabilidade econômica mundial.

Essa dinâmica tem mobilizado o interesse de investidores, agentes financeiros e órgãos governamentais, que procuram compreender o funcionamento desses ativos, quantificar suas vulnerabilidades e estabelecer quadros regulatórios adequados. Contudo, a escabilidade das criptomoedas revelou variáveis críticas de risco, como a fragilidade de protocolos de segurança, a volatilidade excessiva, à ausência de regulamentação uniforme e ao seu possível uso em atividades ilícitas.

O dinamismo destes mercados, operando 24 horas por dia e altamente sensíveis a fatores econômicos, sociais, tecnológicos e geopolíticos, torna a previsão dos seus preços um desafio particularmente complexo (Ghosh et al., 2026). Esta complexidade reforça a necessidade de abordagens analíticas mais sofisticadas, capazes de lidar com padrões não lineares e comportamentos emergentes, justificando o crescente interesse na utilização e técnicas avançadas de Inteligência Artificial (IA) para a modelação e previsão de séries financeiras baseadas em criptomoedas.

Neste contexto, técnicas avançadas de IA, em particular de Aprendizagem de Máquina (*Machine Learning*) (ML), têm sido amplamente aplicadas à previsão de preços de criptomoedas. Entre elas, destacam-se as redes *Long Short Term Memory* (LSTM), introduzidas por Hochreiter e Schmidhuber (1997), reconhecidas pela elevada capacidade de extrair dependências de longo prazo em séries temporais. Outro modelo tradicionalmente utilizado é o Random Forest (RF), que, embora robusto e amplamente utilizado, apresenta limitações na modelação de dinâmicas sequenciais complexas (Bai et al., 2018).

Com o crescimento exponencial de dados financeiros, muitos modelos de ML demonstraram-

se insuficientes para tarefas de previsão de criptomoedas. Em contraste, métodos de Aprendizagem Profunda (*Deep Learning*) (DL) têm ganhado destaque devido à sua capacidade de modelar padrões não lineares e dependências temporais intrínsecas às séries financeiras. Entre estas abordagens, as Redes Convolucionais Temporais (*Temporal Convolutional Networks*) (TCN) têm demonstrado desempenho competitivo e por vezes superior, em tarefas de modelação de sequências complexas (Bai et al., 2018), oferecendo soluções mais robustas para a previsão de ativos altamente voláteis.

Adicionalmente, a escassez de dados históricos em mercados digitais, como o das criptomoedas sustenta a utilização de *data augmentation*, que procura aumentar ou transformar séries temporais, mantendo a estrutura informacional relevante, contribuindo para a melhoria o desempenho dos modelos (Wen et al., 2020).

Neste trabalho, investigou-se o desempenho de diferentes modelos preditivos LSTM, *Gated Recurrent Unit* (GRU), TCN e *Transformer*, em comparação com métodos tradicionais, como o RF, na previsão de séries de preços de Bitcoin, Ethereum e Solana. Para avaliar cada modelo, foram utilizadas métricas amplamente adotadas na previsão de séries temporais, nomeadamente Erro Médio Absoluto (*Mean Absolute Error*) (MAE), Raiz Quadrada do Erro-Médio (*Root Mean Square Error*) (RMSE), Erro Percentual Absoluto Médio (*Mean Absolute Percentage Error*) (MAPE) e Coeficiente de Determinação (*R-square*) (R^2).

Adicionalmente, os modelos de DL foram testados em cenários com e sem *data augmentation*, permitindo analisar o impacto desta técnica na capacidade de generalização dos modelos. Os resultados demonstram a superioridade das arquiteturas profundas na modelação de séries financeiras altamente voláteis, destacando o TCN como uma solução mais robusta. Estes resultados oferecem contributos relevantes para a tomada de decisão em contexto de investimento e para futuras investigações na área da previsão de preços de criptomoedas.

1.1 Objetivos

1.1.1 Objetivo Geral

O objetivo geral deste trabalho é implementar e avaliar diferentes modelos de ML e de DL para realizar previsões de preços das *Bitcoin*, *Ethereum* e *Solana*. Adicionalmente, busca-se

analisar o impacto da *data augmentation* no desempenho dos modelos de DL e comparar com modelos tradicionais.

1.1.2 Objetivos Específicos

Os objetivos específicos deste trabalho incluem:

- Realizar um levantamento da literatura com vista à compreensão do estado da arte na previsão de preços de criptomoedas utilizando técnicas de ML e DL.
- Efetuar um estudo comparativo para identificar quais criptomoedas apresentam maior relevância e utilização no mercado atual.
- Avaliar o desempenho inicial dos modelos LSTM, GRU, TCN e Transformer utilizando dados reais, sem a aplicação de técnicas de *data augmentation*.
- Implementar técnicas de *data augmentation*, nomeadamente *jittering* e *magnitude warping*, e analisar o seu impacto na capacidade de generalização dos modelos de DL.
- Comparar, através de métricas quantitativas (MAE, RMSE, MAPE e R^2), o desempenho dos modelos de DL antes e após a aplicação de *data augmentation*, utilizando o RF como modelo de referência (*baseline*).
- Determinar qual dos modelos apresenta maior robustez, precisão e estabilidade na previsão de preços de criptomoedas em ambientes de elevada volatilidade.

1.2 Estrutura do Trabalho

Com o objetivo de facilitar a compreensão do conteúdo apresentado, este trabalho encontra-se organizado em cinco secções sequenciais, cada uma dedicada a um tópico específico, conforme descrito a seguir:

- **Secção 2 – Fundamentação Teórica:** Apresenta os conceitos essenciais para o desenvolvimento do estudo, abordando criptomoedas, tecnologia *blockchain*, princípios de IA, modelos de ML e DL aplicados a séries temporais financeiras, bem como as técnicas de *data augmentation* utilizadas e os principais trabalhos relacionados.

- **Secção 3 – Materiais e Métodos:** Descreve os materiais utilizados no desenvolvimento do trabalho, incluindo as especificações de *hardware* e *software*, e apresenta a metodologia adotada. São detalhadas as etapas de recolha, análise e pré-processamento dos dados, a aplicação das técnicas de *data augmentation*, a modelação preditiva das criptomoedas, as arquiteturas dos modelos, as métricas de avaliação consideradas e o desenvolvimento de uma interface gráfica para demonstração dos resultados.
- **Secção 4 – Resultados e Discussão:** Apresenta os resultados obtidos pelos diferentes modelos, iniciando com o desempenho do modelo de referência RF, seguido da análise dos modelos de DL aplicados aos conjuntos de dados de Bitcoin, Ethereum e Solana. Inclui ainda a comparação entre os resultados com e sem *data augmentation*, gráficos de perda (*loss*) e previsões, bem como uma discussão crítica das diferenças observadas.
- **Secção 5 – Conclusão:** Sintetiza as principais contribuições do trabalho, apresenta as conclusões finais, identifica as limitações do estudo e propõe direções para trabalhos futuros.

2 Fundamentação Teórica

Nesta secção são apresentados os principais fundamentos que sustentam o presente trabalho, abrangendo desde o surgimento e a consolidação das criptomoedas até aos aspetos técnicos da tecnologia *blockchain*. São igualmente explorados os princípios da previsão de séries temporais financeiras, os algoritmos de ML e DL aplicados, as técnicas de *data augmentation*, as métricas de avaliação adotadas e, por fim, a análise dos trabalhos mais relevantes na área.

2.1 Criptomoedas e Mercado Digital

O avanço tecnológico e a digitalização das transações têm transformado o setor financeiro, destacando-se as criptomoedas como alternativas descentralizadas que desafiam os modelos tradicionais (Bigaton et al., 2025). Desde o surgimento do Bitcoin, estas moedas digitais promovem autonomia financeira, reduzem custos de transação e aumentam a inclusão financeira, embora a falta de regulamentação global limite a sua adoção. Este contexto evidencia oportunidades e desafios, reforçando a importância de compreender os impactos económicos e a perceção dos investidores sobre criptomoedas como ativos de longo prazo (Bigaton et al., 2025).

2.1.1 Evolução Histórica das Moedas Digitais


As primeiras ideias relacionadas com o dinheiro digital surgiram na década de 1980 (Normandin et al., 2025), quando começaram a ser propostos conceitos de moeda eletrónica criptografada. Em 1982, David Chaum apresentou um sistema de contabilidade descentralizado que antecipava várias características das atuais *blockchains* (Kriptomat, s.d.). Em 1983, publicou o artigo *Blind Signatures for Untraceable Payments*, que serviu de base ao eCash, lançado pela DigiCash em 1990 (Reiff, s.d.).

Em 1998, surgiram novas propostas, como o B-Money, de Wei Dai, e o Bit Gold, de Nick Szabo. Ambos apresentavam modelos de dinheiro eletrónico descentralizado e anónimo, mas enfrentaram dificuldades técnicas e regulatórias que impediram a sua adoção em larga escala (Kriptomat, s.d.). Mesmo assim, estes projetos influenciaram diretamente o desenvolvimento do Bitcoin.

O marco decisivo ocorreu com a criação do Bitcoin, em 2009, por uma entidade anónima conhecida como Satoshi Nakamoto. No whitepaper Bitcoin: A Peer-to-Peer Electronic Cash System¹, publicado em 2008, Satoshi Nakamoto descreveu um sistema descentralizado baseado em blockchain como alternativa aos modelos financeiros tradicionais (Fundação Getulio Vargas, 2014). Este opera numa rede ponto a ponto (peer-to-peer, P2P)², permitindo transferências de valor sem intermédios (Nakamoto, 2008).

A primeira transação reconhecida ocorreu em 2010, quando Laszlo Hanyecz comprou duas pizzas por 10.000 *Bitcoins*, valor que, anos mais tarde, corresponderia a milhões de dólares (Kriptomat, s.d.). A partir de 2011, começaram a surgir as *altcoins*, moedas alternativas ao *Bitcoin* que procuravam superar algumas das suas limitações. Entre estas destacam-se o *Litecoin* (2011), criado por Charlie Lee para permitir transacções mais rápidas, e o *Ripple* (2012), destinado a facilitar transferências internacionais.

Evolução das Moedas Digitais: Marcos Chave



Made with Napkin

Figura 1.

Linha Temporal da evolução das moedas digitais

Nota. A Figura 1 foi elaborada pelo autor utilizando a plataforma *Napkin.ai*, disponível em <https://www.napkin.ai/>.

¹ Whitepaper de Satoshi Nakamoto: <https://bitcoin.org/bitcoin.pdf>

² Rede onde as transações ocorrem diretamente entre utilizadores, sem intermediários

2.1.2 Tipos de Criptomoedas

Com a consolidação do Bitcoin, uma nova geração de criptomoedas começou a ser desenvolvida com propósitos distintos, como escalabilidade, execução de contratos inteligentes, anonimato e estabilidade de valor. Os criptoativos³ passaram a ser classificados em categorias como moedas transacionais, plataformas de contratos inteligentes e stablecoins⁴, cada uma com funções e tecnologias específicas.

A Tabela 1 apresenta os principais criptoativos em termos de capitalização de mercado, evidenciando as suas categorias, o ano de lançamento e o respectivo caso de uso. Esta síntese contribui para uma compreensão mais ampla do papel de cada ativo dentro do mercado de criptomoedas e das suas aplicações no ambiente digital.

Tabela 1.

Top Criptoativos por Capitalização e Caso de Uso

Criptoativo	Categoria	Ano	Caso de Uso Principal
Bitcoin (BTC)	Moeda transacional	2009	Reserva de valor e meio de troca
Ethereum (ETH)	Plataforma de contratos inteligentes	2015	Execução de contratos e <i>dApps</i> ^a
Tether (USDT)	<i>Stablecoin</i>	2014	Estabilidade de valor e transferências rápidas
BNB (BNB)	Plataforma / Utilitário	2017	Taxas reduzidas e serviços no ecossistema Binance
Solana (SOL)	Plataforma de contratos inteligentes	2020	Aplicações <i>DeFi</i> , <i>NFTs</i> e alta escalabilidade

Nota. Fonte: elaborada pelo autor com base em dados da CoinMarketCap (n.d.).

^a*dApps*: Aplicações descentralizadas que correm sobre uma blockchain.

Entre as principais características técnicas destacam-se: o uso de blockchain⁵; o proof-of-

³ Ativos digitais baseados em criptografia, que incluem moedas (cryptocurrencies) e tokens

⁴ Moedas digitais com valor estável, geralmente atreladas a moedas tradicionais ou ativos

⁵ Cadeia de blocos imutável que regista transações de forma segura e descentralizada

work (PoW)⁶; e chaves criptográficas assimétricas⁷. Em termos simples, o Bitcoin funciona como uma moeda digital limitada a 21 milhões de unidades, com transações verificadas coletivamente pela rede (Nakamoto, 2008).

O Ethereum, fundado por Vitalik Buterin em 2014, representa o segundo marco do mercado cripto. O seu whitepaper propunha uma blockchain programável, permitindo a execução de contratos inteligentes e dApps. O lançamento oficial ocorreu em julho de 2015, após um financiamento coletivo que arrecadou mais de 18 milhões de dólares (Buterin, 2014).

As suas características técnicas incluem a Ethereum Virtual Machine (EVM)⁸; contas baseadas em estado, rastreando saldos e dados persistentes; e o proof-of-stake (PoS)⁹ desde 2022. A Ethereum utiliza gas¹⁰ para cobrar pela computação e prevenir ciclos infinitos (Buterin, 2014).

A Solana, introduzida em 2017 por Anatoly Yakovenko, é uma blockchain de alto desempenho, projetada para escalabilidade sem comprometer a descentralização. Destaca-se pelo uso do proof-of-history (PoH)¹¹, proof-of-stake (PoS) para consenso com líderes rotativos e execução paralela de transações via Sealevel¹². A Solana atinge até 65.000 TPS¹³ com custos muito baixos (Yakovenko, 2017).

As criptomoedas Bitcoin, Ethereum e Solana operam sobre a tecnologia de blockchain, que garante segurança e descentralização. Esta base tecnológica é essencial para o funcionamento das moedas digitais. A próxima secção abordará a blockchain em detalhe, explicando os seus mecanismos e relevância no contexto das criptomoedas.

2.1.3 Tecnologia *Blockchain*

A tecnologia *blockchain* foi introduzida por Nakamoto (2008) como a base de um sistema de pagamentos eletrónicos descentralizado, projetado para operar sem a necessidade de uma autoridade financeira central. Diferentemente do modelo tradicional de comércio eletrónico, no

⁶Mecanismo de validação de blocos em que mineradores resolvem problemas computacionais para adicionar novos blocos à cadeia

⁷Método de encriptação com chave pública e privada para garantir segurança e assinaturas digitais

⁸Máquina virtual Turing-completa que executa códigos de contratos inteligentes na Ethereum

⁹Mecanismo de consenso em que validadores apostam tokens para confirmar transações, reduzindo consumo energético em comparação ao PoW

¹⁰Unidade de medida para o custo computacional de execução de contratos inteligentes

¹¹Mecanismo que cria registos temporais (timestamps) para ordenar eventos de forma eficiente

¹²Runtime que processa contratos inteligentes em múltiplos núcleos de forma simultânea

¹³Transações por segundo, medida de desempenho da blockchain

qual bancos atuam como intermediários confiáveis, esta abordagem elimina custos de mediação e restrições associadas a transações de pequeno valor.

O sistema proposto fundamenta-se em provas criptográficas, permitindo que duas partes realizem transações diretas de forma segura. Nesse contexto, a moeda digital é definida como uma cadeia de assinaturas digitais, em que cada proprietário transfere o valor ao assinar o *hash* da transação anterior juntamente com a chave pública do próximo destinatário (Nakamoto, 2008).

Um dos principais desafios em sistemas descentralizados é o problema do gasto duplo, que ocorre quando um mesmo ativo digital é utilizado simultaneamente em múltiplas transações. Para mitigar esse problema sem recorrer a uma entidade central, todas as transações são divulgadas publicamente, permitindo que a rede concorde sobre uma única ordem cronológica válida (Nakamoto, 2008).

A organização temporal das transações é garantida por meio de um servidor de carimbo de tempo (*timestamp server*). Este mecanismo agrupa transações em blocos, inclui o *hash* do bloco anterior e publica essa informação na rede, formando uma cadeia contínua. Esta estrutura assegura que qualquer modificação em um bloco invalide todos os blocos subsequentes.

A Figura 2 ilustra esta estrutura, mostrando a sequência de blocos desde o bloco gênese, com transações (*TX*), *timestamps* (marcações de tempo), *nonces* e *hashes* interligados. O *ledger* distribuído mantém a integridade por meio de referências criptográficas ao bloco pai (*parent block*).




Figura 2.

Estrutura de *blockchain*, composta por uma cadeia contínua de blocos interligados

Fonte: Zheng et al. (2018)

A imutabilidade da *blockchain* é reforçada pelo mecanismo de prova de trabalho (*proof-of-work*), no qual os nós da rede realizam cálculos computacionalmente custosos para validar novos blocos. Este processo exige um esforço computacional significativo, tornando economicamente inviável a alteração de registos previamente confirmados (Nakamoto, 2008).

O modelo de consenso adotado segue o princípio de “um CPU, um voto”, no qual a cadeia válida é aquela que representa o maior investimento computacional acumulado. Dessa forma, a corrente mais longa reflete a decisão da maioria honesta da rede, desde que o poder computacional esteja majoritariamente sob controlo de nós legítimos (Nakamoto, 2008).

A segurança do sistema é sustentada tanto pela cooperação coletiva quanto por incentivos económicos. Os participantes que validam blocos recebem recompensas em forma de novas moedas e taxas de transação, tornando mais vantajoso seguir as regras do protocolo do que tentar subvertê-lo. Apesar da transparência das transações, a identidade dos utilizadores permanece preservada por meio do uso de chaves criptográficas (Nakamoto, 2008).

Com o crescimento da cadeia, mecanismos de otimização tornam-se necessários para manter a eficiência do sistema. Nesse sentido, transações antigas podem ser compactadas utilizando Árvores de Merkle, permitindo a verificação da integridade dos dados sem a necessidade de armazenar todo o histórico completo (Nakamoto, 2008).

A *blockchain*, tecnologia que garante integridade e disponibilidade de dados em criptomoedas como *Bitcoin*, *Ethereum* e *Solana*, cria oportunidades para aplicar ferramentas avançadas de análise de mercado. A inteligência artificial, especialmente modelos de aprendizagem profunda, utiliza os *ledgers* distribuídos para treinar algoritmos preditivos em métricas como preços e volatilidade. Além disso, a integração entre IA e contratos inteligentes permite otimizar estratégias de *trading*, aumentando a eficiência e a precisão das análises financeiras. Para o próximo capítulo, exploraremos, portanto, os princípios da IA e as suas aplicações no contexto das criptomoedas estudadas.

2.2 Inteligência Artificial

Introduzida na década de 1950 por John McCarthy (J. Lee et al., 2019), com o surgimento da Indústria 4.0 e o aumento da acessibilidade a grandes volumes de dados, conhecidos como

Big Data, surgiram novas oportunidades para a aplicação da IA, tornando os dados um elemento central para o seu desenvolvimento (Enholm et al., 2022; Govindan, 2022).

A IA é uma área da ciência da computação dedicada ao desenvolvimento de sistemas capazes de realizar tarefas tipicamente humanas, como aprender, raciocinar e tomar decisões. Segundo Russell e Norvig (2021), a IA pode ser entendida como o estudo de agentes racionais que interagem com o ambiente para alcançar objetivos.

A Figura 3, apresentada na Hierarquia das Tecnologias de IA, mostra de forma clara como o campo da IA organiza-se em camadas concêntricas, refletindo níveis progressivos de especialização. Na camada mais externa encontra-se a IA, enquanto campo abrangente que engloba todas as técnicas que aproximam o comportamento das máquinas ao da inteligência humana.

Inserido dentro desta área encontra-se o ML, um subcampo que se dedica ao desenvolvimento de algoritmos capazes de aprender padrões a partir de dados, permitindo a construção de modelos capazes de generalizar e realizar previsões (Mitchell, 1997). Esta abordagem tornou-se particularmente relevante para a modelação de séries temporais financeiras, dado que permite captar dependências estatísticas e dinâmicas complexas.

Dentro do ML localiza-se o DL, representado na imagem como a camada seguinte. O DL utiliza redes neurais profundas capazes de aprender representações hierárquicas e altamente não lineares dos dados (Goodfellow et al., 2016). Estas características fazem com que modelos de DL se destaquem na previsão de preços de criptomoedas, especialmente devido à sua capacidade de capturar dependências temporais longas e padrões dinâmicos que algoritmos tradicionais têm dificuldade em modelar.

Por fim, no núcleo da hierarquia encontram-se os *Large Language Models (LLMs)*, que representam uma aplicação avançada do DL. Embora não sejam o foco central deste trabalho, estes modelos são mencionados para contextualizar a evolução da IA e demonstrar como técnicas inicialmente desenvolvidas para processamento de linguagem natural impulsionaram avanços significativos em arquiteturas como o *Transformer* — uma das abordagens estudadas posteriormente neste capítulo.




Figura 3.

Relação hierárquica entre IA, ML, DL e LLM

Nota. A Figura 3 foi elaborada pelo autor utilizando a plataforma *Napkin.ai*, disponível em <https://www.napkin.ai/>.

2.2.1 Modelos de *Machine Learning*

O ML é uma subárea da IA que procura dotar os sistemas da capacidade de aprender a partir de dados e resolver problemas de forma adaptativa. Criado nos anos 1950 com modelos iniciais, como os *perceptrons*, o ML evoluiu juntamente com a IA, ganhando impulso nos anos 1990 devido a avanços computacionais significativos. Atualmente, engloba técnicas supervisionadas, não supervisionadas e de reforço, sendo aplicado em tarefas de previsão, classificação e agrupamento de dados. Dessa forma, o ML constitui a base prática da IA moderna (Alpaydin, 2020).

A previsão de preços de criptomoedas apresenta desafios como elevada volatilidade, não linearidade e influência de fatores externos. Para lidar com estas características, têm sido aplicados diferentes modelos de ML, que variam desde regressões simples até métodos mais sofisticados, como *ensemble methods*. Estes modelos permitem captar padrões históricos e gerar

previsões mais precisas, sendo fundamentais para análises financeiras e estratégias de *trading*.

2.2.1.1 Random Forest A RF é um algoritmo de aprendizagem em conjunto (*ensemble learning*), ou seja, um método que combina múltiplos modelos para melhorar a precisão das previsões, baseado em árvores de decisão (*decision trees*), que são modelos que realizam previsões seguindo uma sequência de decisões sobre os dados (Breiman, 2001).

O algoritmo opera construindo diversas árvores de decisão independentes, cada uma treinada com um subconjunto aleatório dos dados através de *bootstrap aggregation (bagging)*¹⁴, e selecionando, em cada nó de divisão, um subconjunto aleatório de *features* (características ou variáveis usadas pelo modelo para tomar decisões). As previsões finais são obtidas por votação majoritária, no caso de classificação, ou por média, no caso de regressão, reduzindo o risco de *overfitting* (sobreajuste), que ocorre quando o modelo aprende demasiado os dados de treino, perdendo capacidade de generalização (Breiman, 2001). Assim, a RF torna-se robusta a dados ruidosos, ou seja, dados com variações ou erros aleatórios, e a relações não lineares comuns em mercados financeiros.

A Figura 4 ilustra o processo de construção do modelo, mostrando como múltiplas *decision trees* são treinadas sobre subconjuntos de dados gerados por amostragem *bootstrap*, assegurando diversidade no conjunto de árvores (IBM, 2025).

A predição do modelo *Random Forest* para uma nova amostra x é dada por:

$$f(x) = \frac{1}{N} \sum_{i=1}^N h_i(x) \quad (1)$$

onde:

- N é o número total de árvores na floresta;
- $h_i(x)$ é a predição da i -ésima árvore para a amostra x .

¹⁴Técnica de amostragem aleatória com reposição que permite gerar múltiplos subconjuntos de dados para treinar diferentes árvores, aumentando a diversidade do modelo




Figura 4.

Processo de construção do modelo *Random Forest*

Fonte: Adaptado de IBM (2025)

O modelo de ML tradicional, como a RF, é utilizado em previsões de preços de criptomoedas devido à sua capacidade de lidar com dados ruidosos e relações não lineares. No entanto, estes modelos não conseguem captar dependências temporais de longo prazo, ou seja, relações entre valores passados e futuros numa série temporal. Por esse motivo, métodos de DL surgem como alternativas mais robustas, capazes de modelar padrões sequenciais e dinâmicas complexas do mercado, sendo especialmente úteis em aplicações de previsão de preços de criptomoedas.

2.2.2 Modelos de Deep Learning

O DL é um subcampo do ML baseado em redes neurais artificiais com múltiplas camadas, capazes de aprender representações hierárquicas de dados. Estas redes destacam-se em aplicações que envolvem grandes volumes de informação, como visão computacional, reconhecimento de fala e previsão de séries temporais (Goodfellow et al., 2016). No contexto deste trabalho, utilizam-se modelos como LSTM, GRU, TCN e Transformer, que permitem captar dependências temporais complexas em dados de criptomoedas. Além disso, aplicam-se técnicas de *data augmentation* para mitigar a escassez de dados e melhorar a capacidade de generalização dos modelos.

No âmbito da previsão de preços de criptomoedas, o DL destaca-se pela capacidade de aprender padrões complexos presentes em séries temporais altamente voláteis. Estes modelos lidam eficientemente com não linearidades, dependências de longo prazo e grandes volumes de dados, superando abordagens tradicionais utilizadas em finanças. Nesta subsecção, descrevem-se quatro arquiteturas amplamente adotadas na literatura: *LSTM*, *GRU*, *TCN* e *Transformer*.

2.2.2.1 Long Short-Term Memory A LSTM, proposta por Hochreiter e Schmidhuber (1997), foi desenvolvida para superar o problema do desvanecimento do gradiente presente em RNNs tradicionais. A arquitetura introduz uma célula de memória com três portas principais — de entrada, de esquecimento e de saída — que regulam o fluxo de informação ao longo do tempo. Cada porta actua como um filtro multiplicativo, decidindo quais elementos devem ser retidos ou descartados, permitindo à rede captar dependências de longo alcance em séries temporais (Hochreiter & Schmidhuber, 1997).

Segundo Hochreiter e Schmidhuber (1997), esse controlo estruturado evita a perda de gradiente e possibilita que a rede retenha informações relevantes durante intervalos prolongados. Tal característica é particularmente vantajosa no contexto financeiro, onde eventos passados podem exercer influência significativa na dinâmica futura do mercado.




Figura 5.

Célula LSTM segundo Hochreiter e Schmidhuber (1997)

Fonte: Adaptado de Mittendorf et al. (2022)

Como ilustrado na Figura 5, a célula LSTM é composta por três portas principais que coordenam o fluxo de informação ao longo do tempo. A **porta de esquecimento** decide quais dados do estado anterior devem ser descartados; a **porta de entrada** define quais novos valores serão incorporados ao estado da célula; e a **porta de saída** controla quais informações serão transmitidas para a próxima etapa da rede (KaNaung, 2024).

De acordo com KaNaung (2024), “estas portas trabalham em conjunto para gerir o fluxo de informação dentro da rede, retendo dados essenciais em longas sequências e descartando partes desnecessárias”. Assim, a LSTM mantém a capacidade de captar dependências temporais de longo prazo, característica fundamental em tarefas de previsão baseadas em séries temporais.

2.2.2.2 Gated Recurrent Unit A GRU, proposta por Cho et al. (2014), é uma variação simplificada das LSTM, desenvolvida para reduzir a complexidade computacional, mantendo a capacidade de captar dependências temporais. Ao contrário da LSTM, que utiliza três portões distintos, a GRU recorre apenas a dois: o *update gate* e o *reset gate*. Esta simplificação diminui o número de parâmetros, acelerando o treino sem comprometer significativamente o desempenho em tarefas de previsão sequencial.

O *update gate* controla a proporção de informação passada para o estado oculto seguinte. Em termos , desempenha simultaneamente o papel da porta de entrada e da porta de esquecimento das LSTM, determinando o quanto do estado anterior deve ser preservado. Quando este portão assume valores elevados, a rede tende a manter a memória passada; quando assume valores baixos, favorece a incorporação de nova informação (Cho et al., 2014).

Por sua vez, o *reset gate* decide de que forma a informação anterior deve ser combinada com a nova entrada. Quando este portão assume valores reduzidos, a rede “reinicia” parcialmente a memória, tornando o novo estado menos dependente do passado. Este comportamento é particularmente útil quando as dependências relevantes são de curto prazo, permitindo uma adaptação mais rápida a mudanças abruptas nos dados (Cho et al., 2014).

A Figura 6 apresenta a estrutura da célula GRU, evidenciando o fluxo de informação e a interação entre os dois portões principais.




Figura 6.

Arquitetura interna da célula GRU

Fonte: Adaptado de Consuledge (2024)

2.2.2.3 Temporal Convolutional Network A TCN, introduzida por Bai et al. (2018), é uma arquitetura convolucional desenvolvida para o processamento de sequências temporais. A TCN utiliza dois princípios fundamentais — *dilated convolutions* e *causality* — que lhe permitem captar dependências de longo alcance sem recorrer a mecanismos recorrentes. As convoluções dilatadas inserem intervalos regulares entre os valores do filtro, ampliando o *receptive field* de forma exponencial, sem aumento significativo do número de parâmetros. Este comportamento possibilita a análise de contextos temporais extensos, mantendo a eficiência computacional (Bai et al., 2018).

A Figura 7 apresenta a arquitetura geral da TCN, destacando a utilização de *dilated convolutions* e de *residual connections*, essenciais para preservar a integridade temporal e estabilizar o processo de treino.




Figura 7.

Arquitetura da TCN com fatores de dilatação crescente ($d = 1, 2, 4$)

Fonte: Adaptado de K. Lee et al. (2021)

Os componentes essenciais que definem o funcionamento de uma TCN, segundo Mostafaei et al. (2025), incluem:

- **Convoluções dilatadas (*dilated convolutions*)**: expandem o campo de percepção da rede sem aumentar substancialmente o custo computacional, permitindo captar dependências de longo prazo em séries temporais.
- **Ligações residuais (*residual connections*)**: facilitam o treino de redes profundas ao mitigar o problema do desaparecimento do gradiente, promovendo maior estabilidade e convergência eficiente.
- **Causalidade (*causality*)**: garante que cada previsão utilize exclusivamente informações do presente e do passado, preservando a coerência temporal e assegurando resultados compatíveis com os dados disponíveis no momento.

2.2.2.4 Transformer O *Transformer* é uma arquitetura baseada em mecanismos de atenção, proposta por Vaswani et al. (2017), que elimina a necessidade de recorrência ao modelar relações globais através do mecanismo de *self-attention*. Esta abordagem permite processamento paralelo e a captação de dependências em diferentes escalas temporais, tornando-a particularmente adequada para a modelação de séries temporais complexas. No presente trabalho, utiliza-se uma adaptação desta arquitetura para a previsão de preços, conforme descrito por

Wang et al. (2022). A Figura 8 apresenta a estrutura geral do *Transformer*, destacando os seus componentes fundamentais.




Figura 8.

Arquitetura do modelo Transformer baseado no mecanismo de atenção

Fonte: Adaptado de Vaswani et al. (2017)

- **Incorporações e Codificação Posicional (*Embeddings e Positional Encoding*):** originalmente desenvolvidas no contexto do Processamento de Linguagem Natural (*Natural Language Processing, NLP*), estas técnicas mapeiam sequências para um espaço vetorial de dimensão reduzida. No caso das séries temporais, os valores de entrada são transformados por uma camada de *embedding* e complementados com uma codificação posicional baseada em funções seno e cosseno, permitindo ao modelo distinguir a ordem dos elementos na sequência. A codificação posicional proposta por Vaswani et al. (2017) é

definida por:

$$PE(t, 2s) = \sin\left(\frac{t}{10000^{2s/d}}\right), \quad PE(t, 2s + 1) = \cos\left(\frac{t}{10000^{2s/d}}\right) \quad (2)$$

onde:

- t representa a posição do elemento na sequência temporal;
- s corresponde ao índice da dimensão do vetor de codificação;
- d indica a dimensão total do vetor de *embedding*;
- $PE(t, 2s)$ representa os componentes pares da codificação posicional;
- $PE(t, 2s + 1)$ representa os componentes ímpares da codificação posicional;
- a base 10000 controla a variação das frequências das funções seno e cosseno.

A matriz resultante $PE \in \mathbb{R}^{T \times d}$ é adicionada às incorporações antes de ser encaminhada para o *encoder* (Wang et al., 2022).

- **Arquitetura *Encoder–Decoder*:** à semelhança dos modelos utilizados em tradução automática, o *Transformer* adota uma estrutura composta por um *encoder* e um *decoder*. O *encoder* transforma a sequência de entrada numa representação latente através de camadas de atenção multi-cabeças e redes totalmente conectadas, integrando ligações residuais e normalização. O *decoder* apresenta uma estrutura semelhante, mas incorpora duas operações de atenção: uma aplicada à saída parcial gerada e outra à representação produzida pelo *encoder* (Wang et al., 2022). No contexto deste trabalho, não é necessário o uso de mascaramento, uma vez que as previsões são realizadas exclusivamente com base em dados históricos.
- **Atenção Própria (*Self-Attention*):** conforme descrito por Vaswani et al. (2017), este mecanismo permite ao modelo identificar, para cada elemento da sequência, quais os restantes elementos mais relevantes para a previsão. Como destacado por Wang et al. (2022), a atenção própria demonstrou que modelos de **DL** podem dispensar arquiteturas recorrentes (*RNN*) e convolucionais (*CNN*), substituindo-as por mecanismos de atenção.

A operação de atenção é definida por:

$$Attention(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (3)$$

onde:

- Q representa as consultas (*queries*);
 - K corresponde às chaves (*keys*);
 - V indica os valores (*values*);
 - d_k representa a dimensão das chaves.
- **Atenção Multi-Cabeças (*Multi-Head Attention*)**: este mecanismo executa múltiplas operações de atenção em paralelo, permitindo que cada cabeça aprenda diferentes tipos de relações temporais. Os resultados são concatenados e posteriormente projectados linearmente para produzir a saída final (Vaswani et al., 2017). Matematicamente:

$$MultiHead(Q, K, V) = \text{Concat}(head_1, \dots, head_h) W_O \quad (4)$$

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (5)$$

onde W_i^Q , W_i^K , W_i^V e W_O são matrizes de pesos aprendidas.

Após a caracterização das arquiteturas apresentadas, torna-se fundamental considerar técnicas que melhorem a qualidade e a diversidade dos dados de entrada. Entre estas, o *data augmentation* destaca-se por permitir o aumento do conjunto de dados, a redução do sobreajustamento e a melhoria da capacidade de generalização dos modelos.

2.3 Técnicas de *Data Augmentation*

O *Data Augmentation* consiste num conjunto de técnicas destinadas à geração de padrões sintéticos a partir dos dados de treino existentes. O seu principal objectivo é aumentar a capacidade de generalização dos modelos treinados, reduzindo o risco de *overfitting* (sobreajustamento) e melhorando a robustez das decisões do modelo. Esta abordagem revela-se par-

tualmente relevante em cenários caracterizados por conjuntos de dados reduzidos, como frequentemente ocorre em séries temporais financeiras (Iwana & Uchida, 2021).

Entre as abordagens mais antigas encontram-se os métodos baseados em transformações aleatórias, inspirados inicialmente nas técnicas de *data augmentation* aplicadas a imagens, como a adição de ruído. Técnicas como o *Jittering* e o *Magnitude Warping* inserem-se na categoria das transformações no domínio da magnitude, actuando directamente sobre os valores da série temporal (Iwana & Uchida, 2021).

2.3.1 Jittering

O *Jittering* é uma das técnicas de *data augmentation* baseadas em transformação mais simples, mas simultaneamente eficazes, operando no domínio da magnitude. Esta técnica consiste na adição de ruído aleatório à série temporal original em cada instante temporal, com o intuito de introduzir pequenas perturbações que aumentem a variabilidade dos dados (Iwana & Uchida, 2021).

A formulação matemática do *Jittering* pode ser expressa da seguinte forma:

$$x' = x_1 + \epsilon_1, \dots, x_t + \epsilon_t, \dots, x_T + \epsilon_T, \quad (6)$$

onde:

- x representa a série temporal original;
- x' representa a série temporal aumentada;
- ϵ_t corresponde ao ruído gaussiano adicionado em cada instante temporal t .

Tipicamente, o ruído ϵ_t é amostrado a partir de uma distribuição normal $\mathcal{N}(0, \sigma^2)$, sendo o desvio padrão σ um hiperparâmetro definido previamente. A escolha adequada deste parâmetro é fundamental, uma vez que valores excessivos podem distorcer significativamente a estrutura original da série temporal.

A Figura 9 ilustra este processo: a primeira linha representa as amostras originais, enquanto a segunda apresenta as amostras resultantes após a aplicação do *jittering*, evidenciando as pequenas perturbações introduzidas pelo ruído gaussiano.




Figura 9.

Exemplo de aplicação da técnica de jittering em séries temporais financeiras

Fonte: Adaptado de Nikitin (2023)

2.3.2 Magnitude Warping

O *Magnitude Warping* é uma técnica de *data augmentation* especificamente desenvolvida para séries temporais, enquadrando-se igualmente nas transformações do domínio da magnitude. Este método consiste na distorção gradual da amplitude do sinal através da aplicação de uma curva suavizada ao longo do tempo (Iwana & Uchida, 2021).

A técnica pode ser representada matematicamente por:

$$x' = \alpha_1 x_1, \dots, \alpha_t x_t, \dots, \alpha_T x_T \quad (7)$$

onde:

- x corresponde à série temporal original;
- x' corresponde à série temporal aumentada;
- $(\alpha_1, \dots, \alpha_t, \dots, \alpha_T)$ representa a sequência de factores de *warping*, responsáveis pela distorção da magnitude ao longo do tempo.

A sequência de factores de *warping* é gerada através da interpolação de um *spline* cúbico $S(u)$, definido por um conjunto de nós $u = u_1, \dots, u_i, \dots, u_I$. A magnitude associada a cada

nó u_i é tipicamente amostrada a partir de uma distribuição normal $\mathcal{N}(\mu, \sigma^2)$, onde μ assume geralmente o valor 1. O desvio padrão σ e o número de nós I constituem hiperparâmetros definidos previamente (Iwana & Uchida, 2021).

No contexto de séries temporais financeiras, diversas técnicas de *data augmentation* podem ser aplicadas. A selecção das técnicas utilizadas neste trabalho baseou-se em estudos prévios que demonstraram a sua eficácia em tarefas de previsão de preços de criptomoedas recorrendo a modelos de *Deep Learning*. No entanto, importa salientar que o desempenho destas técnicas depende fortemente do contexto e das características específicas dos dados. Nos capítulos seguintes, descrevem-se de forma sucinta os critérios de selecção e a aplicação das técnicas adoptadas.

2.4 Trabalhos Relacionados

A análise preditiva de preços de criptomoedas, como Bitcoin, Ethereum e Solana, tem recorrido de forma crescente a técnicas de (ML) para modelar séries temporais caracterizadas por elevada volatilidade e comportamento não linear. Este domínio assume particular relevância no contexto de investimentos financeiros e de finanças descentralizadas, onde a instabilidade intrínseca do mercado dificulta a aplicação de modelos estatísticos clássicos. Ao longo do tempo, observa-se uma evolução das abordagens tradicionais para modelos baseados em (DL), capazes de capturar padrões temporais complexos e dependências de longo prazo.

Diversos estudos reportam a aplicação bem-sucedida de modelos de DL na previsão de preços de criptomoedas, destacando uma transição progressiva para arquiteturas mais sofisticadas e, mais recentemente, para modelos híbridos. Paralelamente, algumas investigações exploram técnicas de *data augmentation* como forma de mitigar limitações associadas à escassez ou instabilidade dos dados, visando melhorias na precisão preditiva (Patel et al., 2024).

Na literatura, encontram-se comparações sistemáticas entre modelos tradicionais de ML e arquiteturas de DL. Sebastião e Godinho (2021) aplicaram modelos estatísticos e de aprendizagem automática, incluindo regressões lineares, (RF) e *Support Vector Machines* (SVM), na previsão dos preços de Bitcoin, Ethereum e Litecoin. Os autores verificaram que um *ensemble* desses modelos apresentou elevado desempenho global, sendo a RF o modelo individual com

melhor resultado para Bitcoin, alcançando um RMSE de 5,77.

De forma semelhante, Saadah e Whafa (2020) avaliaram k-NN, SVM e LSTM na previsão de Bitcoin, Ethereum e Ripple, concluindo que a LSTM obteve o menor RMSE em todos os criptoativos analisados. Por sua vez, Derbentsev et al. (2020) compararam RF e *Gradient Boosting Machines* (GBM), observando que o GBM superou consistentemente a RF para todas as moedas consideradas.

No contexto de DL, as arquiteturas recorrentes dominam a literatura devido à sua capacidade de modelar dependências temporais. Modelos como LSTM e GRU são amplamente utilizados em tarefas de previsão financeira. McNally et al. (2018) demonstraram que a LSTM superou uma RNN simples na previsão do preço do Bitcoin, alcançando uma acurácia de 52,78%. De forma mais recente, Li (2025) compararam LSTM, XGBoost e RF, verificando que a LSTM apresentou desempenho superior, com $R^2 = 0,995$, MAE = 0,04 e RMSE = 0,0508. Resultados semelhantes foram reportados por Yu (2025), que avaliaram RF, LSTM e Transformer para Dogecoin, destacando novamente a LSTM como o modelo mais eficaz, com MAE = 0,00096, MSE = 0,0000035 e $R^2 = 0,9989$, evidenciando a sua robustez em séries altamente voláteis.

Arquiteturas mais recentes, como as (TCN) e os Transformers, começam a surgir na literatura aplicada a séries temporais financeiras. Omole e Enke (2024) avaliaram modelos CNN-LSTM, LSTNet e TCN utilizando dados *on-chain* de Bitcoin, comparando-os com o modelo ARIMA. O melhor desempenho foi obtido pelo modelo CNN-LSTM combinado com seleção de características via BORUTA, atingindo uma acurácia de 82,44%, superando claramente o modelo estatístico clássico (Omole & Enke, 2024).

Apesar dos avanços observados, a literatura apresenta lacunas relevantes. A aplicação de Transformers na previsão de preços de criptomoedas permanece limitada, enquanto modelos tradicionais como a RF continuam a apresentar desempenho competitivo, como evidenciado pelo RMSE de 5,77 obtido para Bitcoin (Sebastião & Godinho, 2021). Além disso, técnicas de *data augmentation* são raramente exploradas de forma sistemática, sobretudo em comparação direta com modelos tradicionais, o que evidencia oportunidades claras de investigação. Adicionalmente, observa-se uma escassez de estudos focados em ativos emergentes, como Solana, bem como a ausência de avaliações comparativas utilizando métricas consistentes.

Neste contexto, o presente trabalho propõe uma análise comparativa entre RF, LSTM, GRU, TCN e Transformer na previsão de preços de Bitcoin, Ethereum e Solana. Adicionalmente, são aplicadas técnicas de *data augmentation*, nomeadamente *jittering* e *scaling*, exclusivamente aos modelos de DL, com o objetivo de avaliar o seu impacto no desempenho preditivo. A avaliação é conduzida com base nas métricas RMSE, MAE, MAPE e R^2 , procurando verificar se estas abordagens permitem superar o desempenho da RF enquanto *baseline* clássico. Utilizando dados históricos obtidos do Yahoo Finance, este estudo visa colmatar lacunas existentes na literatura e contribuir para a compreensão da eficácia de modelos avançados e técnicas de *data augmentation* na previsão de preços de criptomoedas.

Tabela 2.

Síntese comparativa de estudos relacionados à previsão de preços de criptomoedas

Autor (Ano)	Criptoativo	Modelo	Resultado Principal
Sebastião & Godinho (2021)	BTC, ETH, LTC	Linear, RF, SVM, <i>Ensemble</i>	RF melhor para BTC (RMSE 5,77), <i>ensemble</i> com alto acerto
Saadah & Whafa (2020)	BTC, ETH, XRP	k-NN, SVM, LSTM	LSTM menor RMSE para todos os criptoativos
Derbentsev et al. (2020)	BTC, ETH, XRP	RF, GBM	GBM superou RF em todas as moedas
McNally et al. (2018)	BTC	LSTM, RNN	LSTM 52,78%, superior à RNN simples
Li (2025)	BTC	LSTM, XGBoost, RF	LSTM melhor: $R^2=0,995$, MAE=0,04, RMSE=0,0508
Yu (2025)	DOGE	RF, LSTM, Transformer	LSTM melhor: MAE=0,00096, MSE=0,0000035, $R^2=0,9989$
Omole & Enke (2024)	BTC	CNN-LSTM, LSTNet, TCN, ARIMA	CNN-LSTM + BORUTA: 82,44%, melhor que ARIMA
Este trabalho	BTC, ETH, SOL	RF, LSTM, GRU, TCN, Transformer	Avaliação com <i>data augmentation</i> (<i>jittering</i> e <i>scaling</i>), visando superar RF

Nota. Fonte: elaborada pelo autor com base em estudos selecionados na literatura.

3 Materiais e Métodos

Esta secção descreve os materiais, procedimentos e métodos utilizados no desenvolvimento do presente estudo, assegurando a sua reprodutibilidade. São apresentadas as fontes de dados, as etapas de pré-processamento, a preparação das sequências com recurso a técnicas de *data augmentation*, bem como as arquiteturas dos modelos e os procedimentos de treino e avaliação.

3.1 Materiais de Desenvolvimento

Os materiais de desenvolvimento foram definidos de acordo com os requisitos computacionais do projeto. A linguagem de programação utilizada foi o Python, devido à sua ampla adoção no meio científico e ao forte suporte a bibliotecas especializadas em análise de dados e DL.

A escolha do Python deve-se ainda à sua sintaxe simples, elevada compatibilidade com bibliotecas de alto desempenho, como *TensorFlow*, *Keras*, *Scikit-learn*, *Pandas* e *NumPy*, bem como à facilidade de integração com ferramentas de visualização e controlo de versões.

Todas as etapas do estudo, incluindo a recolha de dados, o pré-processamento, a modelação e a avaliação dos modelos, foram implementadas em *notebooks Jupyter*. Estes foram executados na plataforma Kaggle, que disponibiliza um ambiente computacional reprodutível, com suporte a GPU.

A utilização do Kaggle permitiu a execução eficiente dos modelos, eliminando a necessidade de configurações locais complexas e assegurando condições consistentes para o treino e a avaliação das arquiteturas consideradas.

3.1.1 Especificações de Hardware

O desenvolvimento do presente estudo foi conduzido num ambiente computacional configurado para suportar tarefas de processamento intensivo. As principais especificações de hardware do sistema utilizado encontram-se resumidas na Tabela 3.

Tabela 3.

Especificações de Hardware e Sistema Operativo

Componente	Especificação
Processador	Intel(R) Xeon(R) CPU @ 2.20GHz
Memória RAM	31.35 GB
Tipo de Sistema	x86_64
Sistema Operativo	Linux-6.6.56+-x86_64-with-glibc2.35

3.1.2 Especificações de Software

Para além das ferramentas anteriormente mencionadas, foram utilizadas diversas bibliotecas destinadas à manipulação e visualização de dados, ao pré-processamento, à modelação em ML e à avaliação de desempenho dos modelos.

Adicionalmente, recorreu-se à biblioteca *Streamlit* para o desenvolvimento de uma interface interativa, permitindo a visualização dinâmica dos resultados e a realização de testes de forma intuitiva.

A Tabela 4 apresenta as principais bibliotecas utilizadas ao longo do estudo, bem como as respetivas versões.

Tabela 4.

Principais Bibliotecas de Software Utilizadas

Biblioteca	Versão	Descrição
NumPy	1.26.2	Biblioteca para computação numérica eficiente com suporte a vetores, matrizes e funções matemáticas.
Pandas	2.1.0	Utilizada para manipulação, análise e organização de dados em estruturas como DataFrames.
Matplotlib	3.8.0	Biblioteca para criação de gráficos e visualizações estáticas e dinâmicas.
Seaborn	0.12.2	Baseada no Matplotlib, permite a criação de gráficos estatísticos com melhor estética.
Scikit-learn	1.3.0	Usada para tarefas de ML, como pré-processamento, regressão, classificação e métricas.
TensorFlow	2.14.0	Framework para desenvolvimento e treinamento de modelos de DL.
Keras	2.14.0	Interface de alto nível para construção de redes neurais sobre o TensorFlow.
SciPy	1.11.2	Biblioteca científica com funções para otimização, estatística, sinais e álgebra linear.
Joblib	1.3.2	Utilizada para salvamento e carregamento eficiente de modelos treinados.
Streamlit	1.28.0	Ferramenta para criação rápida de interfaces web interativas para visualização dos resultados.

3.2 Metodologia de Pesquisa e Etapas de Implementação

Este trabalho adota uma metodologia estruturada em *pipeline*, contemplando etapas de recolha, limpeza e normalização dos dados, aplicação de técnicas de *data augmentation*, construção de janelas temporais, modelação com diferentes arquiteturas de *Deep Learning* e avaliação subsequente do desempenho dos modelos.

Todo o processo de implementação encontra-se devidamente documentado e disponibi-

zado no código-fonte do projeto, organizado num repositório público no GitHub¹⁵, assegurando transparência, reprodutibilidade e rastreabilidade dos experimentos realizados.

A Figura 10 apresenta o fluxo metodológico adotado ao longo do desenvolvimento do estudo.




Figura 10.

Representação do ciclo de desenvolvimento da metodologia

- **Recolha de Dados:** Obtenção de séries históricas das criptomoedas selecionadas a partir de fontes fidedignas;
- **Limpeza dos Dados:** Remoção de inconsistências, registos incompletos e ruído presente nas séries;
- **Normalização dos Dados:** Aplicação de técnicas para padronizar escalas e melhorar a estabilidade e convergência dos modelos;
- **Data Augmentation:** Geração de variações sintéticas das séries temporais, preservando

¹⁵Código-fonte do trabalho: <https://github.com/RodrigoMF545/DeepCoin-Estudo-Comparativo-de-Algoritmos-de-Machine-Learning>

padrões estatísticos, com o objetivo de aumentar a robustez dos modelos e reduzir o *overfitting*;

- **Construção de Janelas Temporais:** Transformação das séries históricas em sequências estruturadas (*sliding windows*) que permitem aos modelos de DL capturar dependências temporais;
- **Modelação de IA:** Aplicação de diferentes arquiteturas de DL, visando capturar as complexas dinâmicas de evolução dos preços;
- **Avaliação de Desempenho:** Utilização de métricas quantitativas e qualitativas para analisar o desempenho dos modelos de ML e DL;
- **Interface Gráfica:** Plataforma experimental que permite testar os modelos com melhores resultados e visualizar previsões de preços das criptomoedas.

3.3 Recolha e Análise dos Dados

Os dados foram obtidos através da biblioteca *yfinance*, que fornece acesso a preços históricos de ações, índices e criptomoedas. Foram selecionadas três criptomoedas com base na relevância de mercado, liquidez e diversidade tecnológica:

- **Bitcoin:** Criptomoeda mais antiga e representativa, servindo como referência para tendências gerais do mercado;
- **Ethereum:** Segunda maior criptomoeda, com infraestrutura de contratos inteligentes, permitindo analisar diferentes dinâmicas de mercado;
- **Solana:** Criptomoeda emergente, conhecida pela elevada velocidade de transação e baixo custo, oferecendo diversidade no comportamento de preços.

Os dados diários (*1d*) foram recolhidos desde a primeira valorização significativa até 02/05/2025. A Tabela 5 apresenta as principais características dos datasets.

Tabela 5.

Características dos Datasets das Criptomoedas

Dataset	Data Início	Data Fim	Número de Amostras
Solana	10/04/2020	02/05/2025	1.849
Ethereum	09/11/2017	02/05/2025	2.732
Bitcoin	17/05/2010	02/05/2025	3.881

Nota. Fonte: elaborada pelo autor a partir de dados históricos do Yahoo Finance. Cada dataset contém os preços diários de abertura, máxima, mínima, fecho e volume de negociação das respectivas criptomoedas.

Cada registo diário segue o padrão *OHLCV* (*Open, High, Low, Close, Volume*). A Tabela 6 apresenta a descrição de cada variável.

Tabela 6.

Descrição das Variáveis OHLCV

Variável	Descrição
Open	Preço de abertura no período diário
High	Preço máximo no período diário
Low	Preço mínimo no período diário
Close	Preço de fechamento no período diário
Volume	Quantidade total negociada no período diário

O pré-processamento consistiu na padronização das colunas de interesse e na remoção de informações de hora, garantindo registos diários consistentes. A Tabela 7 mostra amostras do dataset de Solana após o pré-processamento. Apenas o dataset de Solana é apresentado, uma vez que os restantes datasets seguem o mesmo padrão de *features*.

Tabela 7.

Amostra de Registos da Base de Dados de Solana (Yahoo Finance)

Data	Open	High	Low	Close	Volume
2020-04-10	0.832005	1.313487	0.694187	0.951054	87,364,276
2020-04-11	0.951054	1.049073	0.765020	0.776819	43,862,444
2020-04-12	0.785448	0.956670	0.762426	0.882507	38,736,897
2020-04-13	0.890760	0.891603	0.773976	0.777832	18,211,285
2020-04-14	0.777832	0.796472	0.628169	0.661925	16,747,614

Nota. Fonte: elaborada pelo autor a partir de dados do Yahoo Finance. Cada registro representa um dia de negociação.

A etapa seguinte consiste na análise exploratória, que permite identificar padrões, distribuições e tendências históricas dos criptoativos, preparando os dados para a modelação e avaliação dos modelos preditivos.

3.4 Pré-Processamento

O pré-processamento dos dados constitui uma etapa fundamental no desenvolvimento de modelos preditivos, assegurando a qualidade e consistência das informações utilizadas durante o treino e avaliação. Nesta fase, os dados brutos são organizados, limpos e preparados para modelação, incluindo a verificação de valores ausentes, remoção de inconsistências, divisão em conjuntos de treino e teste, e aplicação de técnicas de normalização para padronizar a escala das variáveis.

3.4.1 Limpeza e Divisão dos Dados

Embora os *datasets* obtidos via API do *Yahoo Finance* apresentassem boa estrutura, realizou-se um processo sistemático de limpeza e organização para garantir que os dados estivessem prontos para modelação. Primeiramente, a coluna de data foi convertida para o tipo *datetime* e os registos foram ordenados cronologicamente, assegurando a sequência temporal correta.

Em seguida, o *DataFrame* foi indexado pela data, facilitando operações temporais subse-

quentes, como o cálculo de retornos ou a construção de janelas deslizantes. Colunas redundantes, como *price*, foram removidas, mantendo apenas as variáveis de interesse (OHLCV).

Registos com valores ausentes foram eliminados, garantindo que as sequências construídas não contivessem lacunas. Por fim, as variáveis selecionadas foram convertidas em matrizes *NumPy* e divididas em conjuntos de treino e teste (80/20), preparando os dados para normalização e modelação.

3.4.2 Normalização dos Dados

Para uniformizar a escala das *features* e favorecer a convergência dos modelos de aprendizagem, os conjuntos de treino foram normalizados utilizando o *MinMaxScaler*, da biblioteca *Scikit-learn*¹⁶. Este método transforma cada valor para o intervalo $[0, 1]$, preservando a distribuição relativa dos dados.

A normalização foi realizada separadamente: o *scaler* foi ajustado apenas aos dados de treino e, posteriormente, aplicado aos dados de teste, prevenindo a contaminação por informações futuras.

A transformação para cada valor x_i da *feature* X segue a fórmula:

$$x_i^{norm} = \frac{x_i - X_{\min}}{X_{\max} - X_{\min}} \quad (8)$$

onde $X_{\min}$ e $X_{\max}$ correspondem aos valores mínimo e máximo da *feature* no conjunto de treino.

Para verificar a eficácia da normalização, foram gerados gráficos das três bases de dados (Bitcoin, Ethereum e Solana), mostrando as *features* normalizadas ao longo do tempo (Figura 11).

¹⁶<https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.MinMaxScaler.html>




Figura 11.

Features normalizadas da base de treino do Bitcoin, com procedimento equivalente para Ethereum e Solana.

Com a normalização concluída, os dados encontram-se preparados para a construção de sequências temporais e para a aplicação de algoritmos preditivos.

Para aumentar a robustez dos modelos e melhorar a capacidade de generalização face a variações futuras nos preços, aplicam-se técnicas de *data augmentation*. Estas técnicas introduzem pequenas perturbações nos dados normalizados, preservando padrões relevantes e estruturais das séries temporais.

3.5 Aplicação do Data Augmentation

Com os dados normalizados, procedeu-se ao aumento do conjunto de treino através de técnicas de *data augmentation*. O objetivo é incrementar a diversidade das amostras, melhorando a capacidade de generalização dos modelos preditivos.

Para esta etapa, implementaram-se os métodos de *data augmentation* descritos na seção se-

guinte, incluindo *jittering* e *magnitude warping*, garantindo consistência com as características temporais e estatísticas dos dados originais.

Foram aplicadas duas técnicas principais de *data augmentation*:


- ***Jittering***: Este método introduz pequenas perturbações aleatórias na série temporal através da adição de ruído Gaussiano com média nula ($\mu = 0$). O desvio padrão foi definido como $\sigma = 0.005$, garantindo que as alterações permaneçam de baixa magnitude e não comprometam significativamente a dinâmica do sinal. Esta abordagem aumenta a robustez do modelo a variações locais e é amplamente utilizada em séries temporais, conforme sugerido por Um et al. (2017), citado por Iwana e Uchida (2021).
- ***Magnitude Warping***: Esta técnica visa simular variações lentas e não lineares na amplitude do sinal, preservando a sua estrutura temporal. Consiste na multiplicação da série original por uma curva suave gerada por interpolação *spline* cúbica, permitindo distorções contínuas ao longo do tempo. O parâmetro *max_drift* foi definido como 0.03, limitando o desvio percentual máximo da amplitude a $\pm 3\%$. O parâmetro *n_drift_points* = 3 define o número de nós de interpolação, assegurando variações graduais e suaves, conforme proposto em Contributors (2025) da biblioteca *tsaug*.

Deste modo, cada conjunto de treino passou a conter três vezes mais amostras, preservando as tendências originais das séries e introduzindo pequenas variações que auxiliam os modelos a aprender padrões mais robustos, reduzindo o risco de *overfitting*. A expansão do conjunto de dados pode ser visualizada na Figura 12.

Tabela 8.

Número de Amostras dos Datasets das Criptomoedas antes e após Data Augmentation

Dataset	Treino	Teste	Total Sem Augmentation	Total Com Augmentation
Bitcoin	3.044	717	3.761	9.132
Ethereum	2.125	487	2.612	6.375
Solana	1.419	310	1.729	4.257

**Figura 12.**

Coluna *Close* com *Jittering* e *Drift*.

A escolha combinada de *Jittering* e *Magnitude Warping* justifica-se pela complementaridade entre as técnicas. O *Jittering* introduz variações locais e pontuais, enquanto o *Magnitude Warping* simula alterações graduais na tendência das séries temporais. Estudos recentes indicam que a combinação destas técnicas aumenta a variabilidade e o realismo dos dados, melhorando a capacidade de generalização dos modelos e reduzindo o risco de *overfitting* em contextos financeiros voláteis.

3.6 Detalhes de Treinamento dos Modelos

Esta secção descreve a configuração experimental adotada no estudo, incluindo as arquiteturas dos modelos, os hiperparâmetros de treino e as estratégias comuns aplicadas tanto aos modelos de DL como ao modelo *baseline* RF.

3.6.1 Arquitetura dos Modelos

Foram avaliados cinco modelos: um modelo *baseline* RF e quatro modelos de DL (LSTM, GRU, TCN e Transformer). Cada modelo teve a sua arquitetura adaptada às características específicas da abordagem. Os valores apresentados correspondem aos hiperparâmetros mais testados durante o processo de otimização e aos mais utilizados na literatura, assegurando desempenho consistente e comparabilidade entre modelos. A Tabela 9 apresenta as principais configurações adotadas.

Tabela 9.

Estrutura das Arquiteturas dos Modelos de Previsão de Preços de Criptomoedas

Modelo	Camadas Principais	Unidades / Filtros	Regularização	Dropout
RF	Árvores de decisão	100 estimadores	–	–
LSTM	2 LSTM + Dense	100 / 64	L2 (0.01)	0.3
GRU	2 GRU + Dense	100 / 64	L2 (0.01)	0.3
TCN	Conv1D + blocos residuais	64 / 32	–	0.2
Transformer	Atenção + Dense	64 / 128	L2 (0.01)	0.3

Observa-se que os modelos recorrentes (LSTM e GRU) utilizam duas camadas recorrentes seguidas de uma camada densa. O modelo TCN baseia-se em convoluções temporais organizadas em blocos residuais, permitindo capturar dependências de longo alcance sem recorrer à recorrência.

O Transformer utiliza mecanismos de atenção para modelar dependências temporais globais, dispensando estruturas recorrentes e convolucionais. O modelo RF é utilizado como referência, por não depender de arquiteturas neurais nem de treino iterativo baseado em gradiente.

3.6.2 Hiperparâmetros de Treinamento

Para assegurar uma comparação justa entre os modelos de DL, foi adotada uma configuração comum de hiperparâmetros de treino. Esta padronização reduz distorções associadas ao processo de otimização e permite avaliar de forma consistente o impacto das diferentes arquiteturas no desempenho preditivo.

A Tabela 10 apresenta os principais parâmetros utilizados durante o processo de treino.

Tabela 10.

Hiperparâmetros de Treinamento dos Modelos de *Deep Learning*

Parâmetro	Valor / Configuração
Divisão dos Dados	80% treino / 20% teste
Normalização	<i>MinMaxScaler</i>
Otimizador	Adam
<i>Learning Rate</i>	0.001
Função de Perda	<i>Mean Squared Error (MSE)</i>
Epochs	100
Batch Size	32
Callbacks	EarlyStopping (patience = 15), ReduceLROnPlateau (factor = 0.2)

O otimizador Adam foi escolhido devido à sua eficiência e à sua ampla utilização em problemas de séries temporais. As estratégias *EarlyStopping* e *ReduceLROnPlateau* contribuem para mitigar o *overfitting* e melhorar a estabilidade do processo de treino.

Ressalta-se que estes hiperparâmetros não se aplicam ao modelo Random Forest, uma vez que este não requer definição de *learning rate*, *batch size* ou número de *epochs*.

3.7 Métricas de Avaliação dos Modelos

Após o processo de treino e validação dos modelos preditivos descritos na secção anterior, torna-se fundamental proceder à avaliação quantitativa do desempenho das previsões. Nesta

subseção, apresentam-se as métricas utilizadas para medir a precisão dos modelos aplicados à previsão dos preços de fecho das criptomoedas Bitcoin, Ethereum e Solana.

As métricas selecionadas foram o Erro Médio Absoluto (MAE), o Erro Percentual Absoluto Médio (MAPE), a Raiz do Erro Quadrático Médio (RMSE) e o Coeficiente de Determinação (R^2), amplamente utilizadas na literatura para avaliação de modelos de regressão em séries temporais financeiras.

3.7.1 Erro Médio Absoluto (MAE)

O Erro Médio Absoluto (*Mean Absolute Error – MAE*) mede a magnitude média dos erros de previsão, independentemente da sua direção. Trata-se de uma métrica intuitiva, pois expressa o erro médio esperado entre os valores previstos e os valores reais, sendo de fácil interpretação (Willmott & Matsuura, 2005).

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (9)$$

onde:

- n representa o número de observações,
- y_i corresponde ao valor real,
- $\hat{y}_i$ corresponde ao valor previsto.

3.7.2 Erro Percentual Absoluto Médio (MAPE)

O Erro Percentual Absoluto Médio (*Mean Absolute Percentage Error – MAPE*) avalia a precisão das previsões em termos percentuais, calculando a média dos erros relativos em relação aos valores reais (De Myttenaere et al., 2016).

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (10)$$

Os termos mantêm a mesma definição apresentada para o MAE. O MAPE é particularmente útil quando se pretende interpretar os erros de previsão numa escala percentual, facilitando a

comparação do desempenho entre diferentes ativos financeiros.

3.7.3 Raiz do Erro Quadrático Médio (RMSE)

A Raiz do Erro Quadrático Médio (*Root Mean Squared Error – RMSE*) corresponde à raiz quadrada da média dos quadrados dos erros de previsão, atribuindo maior peso a desvios de maior magnitude (Chai & Draxler, 2014). Esta característica torna a métrica mais sensível a erros elevados.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (11)$$

onde os termos apresentam a mesma definição anterior. Em contextos financeiros, o RMSE é particularmente relevante, uma vez que grandes desvios podem acarretar impactos significativos na tomada de decisão.

3.7.4 Coeficiente de Determinação (R^2)

O Coeficiente de Determinação (*R-squared – R^2*) indica a proporção da variância da variável dependente que é explicada pelo modelo. O seu valor varia entre 0 e 1, sendo valores mais próximos de 1 indicativos de um melhor ajustamento do modelo aos dados observados (Wright, 1921).

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (12)$$

onde:

- y_i representa o valor real,
- $\hat{y}_i$ representa o valor previsto,
- $\bar{y}$ corresponde à média dos valores reais,
- n representa o número de observações.

3.8 Interface Gráfica

As interfaces gráficas de previsão desempenham um papel relevante no processo de avaliação de modelos preditivos, especialmente no contexto financeiro, onde decisões precisam ser tomadas de forma rápida e informada. Para além da apresentação de resultados, essas interfaces funcionam como uma camada complementar à avaliação quantitativa tradicional.

Enquanto métricas globais, como MAE ou RMSE, sintetizam o erro médio do modelo, elas não explicam como nem quando ocorrem discrepâncias ao longo do tempo. Nesse sentido, interfaces gráficas permitem analisar o comportamento dinâmico das previsões, identificar padrões temporais e incorporar conhecimento humano no processo de validação.

Visualizações interativas complementam as métricas quantitativas ao possibilitar a inspeção visual de resíduos e a comparação detalhada entre séries reais e previstas. Segundo Karthisha et al. (2025), dashboards financeiros interativos simplificam a interpretação dos dados, auxiliando na identificação de tendências e no suporte à tomada de decisão em investimentos.

As visualizações interativas oferecem diversos benefícios para a análise de séries temporais complexas, nomeadamente:

- **Deteção de padrões e anomalias:** gráficos dinâmicos, como séries temporais interativas e *heatmaps*, permitem identificar comportamentos recorrentes e eventos atípicos que métricas agregadas podem ocultar.
- **Exploração multidimensional:** possibilitam a análise simultânea de diferentes aspectos, como valores observados *versus* previstos ou variáveis correlacionadas.
- **Envolvimento do utilizador:** a interação direta, por meio da seleção de janelas temporais ou cenários, torna o analista um agente ativo no processo de exploração dos dados.

Um exemplo de interface de previsão é apresentado na Figura 13, onde gráficos interativos exibem comparações entre valores reais e previsões dos modelos. Esse tipo de ferramenta facilita a observação do comportamento preditivo ao longo do tempo, auxiliando na identificação de padrões ou anomalias.



Figura 13.

Interface de Previsão de Preços de Criptomoedas.

Nota. A interface apresenta comparações entre valores reais e previsões dos modelos. Fonte:

Adaptado de <https://www.crypticorn.com/ai-crypto-price-prediction-dashboard/>

Para a implementação prática, foi explorada uma biblioteca moderna que facilita a incorporação de visualizações interativas em fluxos de trabalho de ciência de dados. *Frameworks* como o *Streamlit*¹⁷ permitem desenvolver rapidamente dashboards que integram modelos preditivos, gráficos e controles interativos.

¹⁷*Streamlit* é uma biblioteca *open-source* em Python para criação de aplicações web interativas voltadas à visualização de dados e modelos de *Machine Learning*. Disponível em: <https://streamlit.io/>




Figura 14.

Interface de Previsão de Preços de Criptomoedas.

Nota. Interface elaborada pelo autor

4 Resultados e Discussões

Nesta secção, apresentam-se os resultados obtidos com a aplicação de modelos de ML e DL na previsão dos preços das criptomoedas Bitcoin, Ethereum e Solana. Inicia-se com a análise de desempenho do modelo RF, seguida da avaliação dos modelos de DL. Os resultados são comparados considerando duas condições experimentais: sem *data augmentation* e com *data augmentation*.

4.1 Resultados do Modelo: Random Forest


O RF foi utilizado como o modelo *baseline* para a previsão dos preços das criptomoedas *Bitcoin*, *Ethereum* e *Solana*, evidenciando uma forte capacidade de predição mesmo em cenários com dados limitados. A aplicação do modelo apresentou resultados consistentes para as três criptomoedas analisadas. A Tabela 11 apresenta os resultados obtidos no conjunto de teste, evidenciando a capacidade do modelo em capturar padrões complexos mesmo com um volume limitado de dados. Entre os ativos analisados, *Solana* e *Ethereum* apresentaram os melhores resultados de MAE (0,64 e 3,68, respetivamente), acompanhados de coeficientes de determinação R^2 superiores a 0,99.

Tabela 11.


Desempenho do modelo Random Forest para Solana, Ethereum e Bitcoin (dados de teste).

Criptomoeda	MAE	RMSE	MAPE	R-Square
Solana	0.64	1.22	0.35%	0.998837
Bitcoin	6294.85	12969.32	6.92%	0.722123
Ethereum	3.68	5.17	0.13%	0.999932


Os resultados numéricos sugerem que o modelo se ajustou de forma eficaz às séries de Solana e Ethereum, o que é confirmado graficamente pela proximidade entre as curvas de valores reais e previstos. Nas Figuras 15a, 15b e 15c, observa-se como as previsões estão alinhadas com a evolução temporal dos preços.



(a) Solana



(b) Bitcoin



(c) Ethereum

Figura 15.

Comparação entre valores reais e previsões do modelo Random Forest para Solana, Bitcoin e Ethereum.

Entretanto, a Figura 15b evidencia o desempenho do RF para o Bitcoin, reproduzindo com

precisão as oscilações complexas do período de treino e mantendo estabilidade preditiva no período de teste, apesar da forte volatilidade recente. Embora não capture integralmente os picos pós-2024, o modelo preserva a tendência geral, comportamento que reforça os valores observados nas métricas, sobretudo o elevado R^2 e o MAPE de 6,92%, que indicam bom desempenho, apesar de o MAE ter aumentado devido à volatilidade do ativo.

Dessa forma, o gráfico indica que o RF se adapta melhor em séries não lineares, ao mesmo tempo que se inicia o estudo dos modelos de DL, utilizados para extrair movimentos de maior volatilidade.


4.2 Resultados dos Modelos de Deep Learning

Nesta subsecção, são apresentados e discutidos os resultados obtidos pelos modelos de Deep Learning na previsão dos preços de Bitcoin, Ethereum e Solana, considerando dois cenários distintos: com e sem *data augmentation*. A análise é estruturada por modelo, permitindo avaliar como cada arquitetura responde às diferentes condições de treino.


Para cada *dataset*, utilizam-se gráficos de *loss* agregados por *dataset* (Bitcoin, Ethereum e Solana), mostrando simultaneamente os quatro modelos. A análise comportamental das previsões apenas será demonstrada para o modelo RF, devido à grande quantidade de gráficos.

4.2.1 Resultados do Treinamento dos Modelos no Dataset Bitcoin

Como primeira análise, focaremos no *dataset* da criptomoeda Bitcoin. Comparando os valores de *loss* durante o treino e de *validation loss* durante o período de teste, relativamente aos modelos LSTM, GRU, TCN e Transformer, observa-se através da Figura 17 que, na presença dos dois cenários — sem *data augmentation* e com *data augmentation* —, os modelos tiveram bom desempenho, sem evidenciar *overfitting* ou *underfitting*, sendo que o TCN obteve a melhor *performance*, considerando os valores mais próximos de zero.



(a) Gráficos de Treinamento e Validação do Loss (sem augmentation)



(b) Gráficos de Treinamento e Validação do Loss (com augmentation)

Figura 16.

Comparação dos gráficos de Loss de treinamento e validação dos modelos no dataset Bitcoin, antes e depois da aplicação de data augmentation.

Para complementar essa observação qualitativa, a Tabela 12 apresenta as métricas de desempenho de cada modelo, permitindo avaliar o efeito da aplicação de *data augmentation* sobre o *dataset* do Bitcoin.

A Tabela 12 mostra que o TCN foi o modelo com melhor desempenho geral, apresentando

os menores erros MAE, RMSE e MAPE (1566,40; 2293,38; 2,33%, respetivamente) e o maior R^2 de 0,9910, sobretudo após a aplicação de *data augmentation*. O LSTM também melhorou com a aplicação do *data augmentation*, reduzindo significativamente os erros e aumentando a sua capacidade de explicação. O Transformer apresentou o pior desempenho nos dois cenários, evidenciando dificuldade em extrair os padrões temporais do Bitcoin com o tamanho do *dataset*. No geral, os resultados mostram que a arquitetura convolucional TCN foi a que melhor respondeu à aplicação de *data augmentation*.


Tabela 12.

Desempenho dos modelos preditivos para Bitcoin, com e sem Data Augmentation.


Modelo	Dataset	Augmentation	MAE	RMSE	MAPE	R^2
LSTM	Bitcoin	Falso	7331.66	10752.73	9.53%	0.8013
LSTM	Bitcoin	Verdadeiro	5117.18	8505.45	6.34%	0.8757
GRU	Bitcoin	Falso	4227.35	6510.70	5.49%	0.9272
GRU	Bitcoin	Verdadeiro	5448.27	9467.43	6.56%	0.8460
TCN	Bitcoin	Falso	2707.53	3464.89	4.16%	0.9794
TCN	Bitcoin	Verdadeiro	1566.40	2293.38	2.33%	0.9910
Transformer	Bitcoin	Falso	8591.46	14547.61	10.43%	0.6364
Transformer	Bitcoin	Verdadeiro	8693.70	14663.97	10.37%	0.6305

4.2.2 Resultados do Treinamento dos Modelos no Dataset Ethereum

De seguida, daremos continuidade à exploração dos resultados do *dataset* Ethereum. Comparando os valores de *loss* durante o treino e de *validation loss* durante o período de teste, relativamente aos modelos LSTM, GRU, TCN e Transformer, observa-se através da Figura 18b que, nos dois cenários, os modelos tiveram bom desempenho, sendo que o TCN apresentou o melhor desempenho.



(a) Gráficos de Treinamento e Validação do Loss (sem augmentation)



(b) Gráficos de Treinamento e Validação do Loss (com augmentation)

Figura 17.

Comparação dos gráficos de Loss de treinamento e validação dos modelos no dataset Ethereum, antes e depois da aplicação de data augmentation.

A Tabela 13 apresenta o desempenho dos modelos LSTM, GRU, TCN e Transformer no dataset Ethereum, com e sem data augmentation.

O TCN obteve o melhor desempenho geral, alcançando os menores valores de MAE, RMSE e MAPE (79,20; 110,74; 2,77%, respectivamente) e o maior R^2 (0,9673) após a aplicação de data

augmentation, demonstrando elevada precisão e robustez. O Transformer apresentou resultados muito próximos do TCN, com métricas similares quando a *data augmentation* foi aplicada (MAE 79,78; RMSE 112,07; MAPE 2,77% e R^2 0,9665).

Os modelos LSTM e GRU melhoraram significativamente com a *data augmentation*, mostrando que a técnica contribuiu para a generalização: o LSTM reduziu o MAE de 151,03 para 101,14, enquanto o GRU passou de 94,35 para 84,52.


Tabela 13.

Desempenho dos modelos preditivos para Ethereum, com e sem Data Augmentation.


Modelo	Dataset	Augmentation	MAE	RMSE	MAPE	R^2
LSTM	Ethereum	Falso	151.03	198.26	5.06%	0.8952
LSTM	Ethereum	Verdadeiro	101.14	138.36	3.58%	0.9490
GRU	Ethereum	Falso	94.35	129.74	3.31%	0.9551
GRU	Ethereum	Verdadeiro	84.52	118.39	2.96%	0.9626
TCN	Ethereum	Falso	96.73	126.73	3.31%	0.9572
TCN	Ethereum	Verdadeiro	79.20	110.74	2.77%	0.9673
Transformer	Ethereum	Falso	92.94	124.34	3.25%	0.9588
Transformer	Ethereum	Verdadeiro	79.78	112.07	2.77%	0.9665

4.2.3 Resultados do Treinamento dos Modelos no Dataset Solana

Para finalizar, analisaremos a criptomoeda Solana. Comparando os valores de *loss* durante o treino e de *validation loss* durante o teste, relativamente aos modelos LSTM, GRU, TCN e Transformer, observa-se através da Figura 18 que, na presença dos dois cenários, todos os modelos convergem rapidamente para valores próximos de zero, tanto no treino como na validação, indicando treino estável, ausência de *overfitting* e *underfitting*, e demonstrando que os modelos conseguem aprender adequadamente os padrões da série temporal da Solana.



(a) Gráficos de Treinamento e Validação do Loss (sem augmentation)



(b) Gráficos de Treinamento e Validação do Loss (com augmentation)

Figura 18.

Comparação dos gráficos de Loss de treinamento e validação dos modelos no dataset Ethereum, antes e depois da aplicação de data augmentation.

A Tabela 14 mostra que todas as arquiteturas melhoraram com a aplicação de *data augmentation*, reduzindo os erros de MAE, RMSE e MAPE e aumentando o R^2 , o que indica maior capacidade de generalização. Entretanto, tal como nos outros *datasets*, o TCN apresentou o melhor desempenho geral, alcançando os menores valores de MAE, RMSE e MAPE (6,47;

8,63; 3,85%, respetivamente), seguido pelo GRU. O Transformer também beneficiou do *data augmentation*, mostrando maior sensibilidade ao tamanho do *dataset*.

Tabela 14.

Desempenho dos modelos preditivos para Solana, com e sem Data Augmentation.

Modelo	Dataset	Augmentation	MAE	RMSE	MAPE	R ²
LSTM	Solana	Falso	11.05	15.13	6.24%	0.8416
LSTM	Solana	Verdadeiro	8.17	10.85	4.95%	0.9185
GRU	Solana	Falso	7.79	10.32	4.61%	0.9263
GRU	Solana	Verdadeiro	7.32	9.69	4.40%	0.9350
TCN	Solana	Falso	6.93	9.37	4.06%	0.9393
TCN	Solana	Verdadeiro	6.47	8.63	3.85%	0.9485
Transformer	Solana	Falso	8.41	11.26	4.81%	0.9122
Transformer	Solana	Verdadeiro	7.05	9.29	4.16%	0.9403

Nota. Valores em negrito vermelho indicam o pior desempenho de cada modelo; valores em negrito verde escuro indicam o melhor desempenho.

5 Discussões

Este estudo procurou avaliar a capacidade preditiva de modelos de ML e DL na previsão dos preços das criptomoedas Bitcoin, Ethereum e Solana, sob diferentes cenários experimentais. Os resultados revelam detalhes importantes sobre a adequação de cada abordagem, bem como sobre a influência de técnicas complementares, como o *data augmentation*.

O RF destacou-se pelo desempenho consistente em todos os *datasets* analisados, funcionando de forma robusta mesmo com volumes de dados relativamente reduzidos. Este resultado reforça a eficácia do RF em obter previsões gerais das séries temporais, especialmente para ativos como Ethereum e Solana, que apresentaram menor volatilidade comparativa. No entanto, ao avaliar o comportamento do RF face ao Bitcoin, observa-se que, embora o modelo reproduza

satisfatoriamente a tendência geral, falha em capturar picos de elevada volatilidade, sugerindo um possível sobreajuste aos dados de treino e uma limitação na generalização para cenários de maior instabilidade.

Em contraste, os modelos de DL — LSTM, GRU, TCN e Transformer — revelaram maior sensibilidade ao aumento de dados. Entre eles, o TCN destaca-se como o modelo mais consistente, apresentando os menores erros (MAE, RMSE e MAPE) e os maiores valores de R^2 , especialmente após a aplicação de *data augmentation*. Este desempenho evidencia a capacidade do TCN de capturar padrões temporais complexos, respondendo com maior fidelidade às oscilações de curto prazo observadas em todas as criptomoedas estudadas.

Os modelos LSTM e GRU também beneficiaram do aumento do *dataset*, melhorando a capacidade de generalização e reduzindo erros de predição. Esta melhoria é particularmente relevante no caso do Bitcoin, cuja elevada volatilidade exige modelos capazes de aprender rapidamente padrões de curto prazo sem comprometer a coerência das tendências globais. O Transformer, embora não originalmente projetado para séries temporais, demonstrou desempenho competitivo em ativos menos voláteis, como Solana, evidenciando o potencial de arquiteturas baseadas em atenção quando aplicadas a volumes de dados substanciais.

A comparação entre criptomoedas revela *insights* interessantes: enquanto Ethereum e Solana apresentaram padrões mais estáveis e previsíveis, permitindo que tanto o RF como os modelos de DL atingissem altos níveis de precisão, o Bitcoin exigiu uma modelação mais sofisticada devido às flutuações de preço. Este contraste evidencia que a escolha do modelo deve considerar não apenas o tipo de arquitetura, mas também a natureza do ativo financeiro e a disponibilidade de dados históricos.

Do ponto de vista metodológico, o uso de *data augmentation* mostrou-se importante para melhorar o desempenho dos modelos de DL, permitindo a redução de erros e o aumento da capacidade de generalização. Ainda assim, os resultados indicam que, mesmo com estas técnicas, apenas o TCN superou consistentemente o RF no cenário do Bitcoin, reforçando a ideia de que modelos tradicionais podem apresentar desempenho competitivo em cenários com dados limitados, mas são menos adaptáveis a padrões temporais altamente voláteis.

Em termos de limitações, importa salientar que este estudo utilizou *datasets* relativamente

restritos em termos de histórico temporal, o que pode impactar a capacidade de generalização dos modelos, especialmente dos mais complexos, como o Transformer. Além disso, as previsões foram realizadas para um horizonte temporal específico, não abrangendo eventos extraordinários que possam alterar drasticamente os padrões de preço.

Por fim, os achados desta secção indicam que uma abordagem híbrida, combinando a consistência de modelos clássicos como o RF com a capacidade de extração de padrões temporais dos modelos de DL, pode representar uma estratégia promissora para a previsão de preços de criptomoedas. Esta perspectiva abre espaço para investigações futuras, incluindo o estudo de arquiteturas híbridas e de técnicas avançadas de aumento de dados, visando maximizar a precisão e a capacidade de generalização face à volatilidade do mercado.

6 Conclusão

Com base no trabalho apresentado, a investigação teve como objetivo avaliar o desempenho dos modelos de ML e DL na previsão dos preços das criptomoedas Bitcoin, Ethereum e Solana, bem como analisar de que forma as técnicas de *data augmentation* podem influenciar o desempenho dos modelos. Como ponto de partida da questão central — verificar se os modelos de DL podem superar o desempenho do modelo RF mediante o aumento dos dados — estruturou-se uma análise comparativa com quatro modelos de DL: LSTM, GRU, TCN e Transformer.

Dos resultados, observou-se que o modelo RF apresentou desempenho consistente, sobretudo para Ethereum e Solana, com erros reduzidos e coeficientes de determinação superiores. Contudo, verificou-se também um padrão de *overfitting*, especialmente no *dataset* Bitcoin, em que o modelo teve dificuldade em generalizar períodos de elevada volatilidade.

A aplicação do *data augmentation* melhorou o desempenho da maioria dos modelos de DL. Entre eles, o TCN destacou-se como o modelo com resultados mais satisfatórios, sendo o único a superar o RF no *dataset* de Bitcoin. Os restantes modelos (LSTM e GRU) também apresentaram melhorias com a aplicação do *data augmentation*, evidenciando maior capacidade de aprendizagem. O Transformer, apesar de ser originalmente concebido para NLP, demonstrou resultados promissores na extração de padrões do *dataset* de Ethereum, indicando potencial para exploração desta arquitetura em séries temporais.

De um modo geral, com base nos resultados obtidos, o objetivo do estudo foi parcialmente alcançado: embora o aumento de dados tenha melhorado o desempenho dos modelos de DL, apenas o TCN conseguiu superar o modelo RF, e apenas no *dataset* de Bitcoin. Isto indica que o *data augmentation* contribuiu para a capacidade preditiva, mas não garantiu a superioridade dos modelos de DL em todos os cenários.

6.1 Trabalhos futuros

Com base nos resultados e limitações observadas neste estudo, destacam-se quatro direções promissoras para pesquisas futuras:

- **Modelos híbridos e *ensembles*:** Combinar RF com arquiteturas de DL, como TCN

ou Transformer, pode explorar forças complementares, capturando simultaneamente padrões lineares e não lineares, aumentando a precisão preditiva.

- **Exploração de Transformers especializados:** Investigar variantes adaptadas para séries temporais, como o Temporal Fusion Transformer (TFT), pode otimizar a captura de padrões de volatilidade complexos, especialmente em mercados de criptomoedas altamente dinâmicos.
- **Aprimoramento das técnicas de *data augmentation*:** Métodos avançados, como a geração de séries temporais sintéticas via GANs ou simulações estocásticas, podem produzir cenários de treino mais diversificados e realistas, fortalecendo a capacidade de generalização dos modelos.
- **Integração com métricas de risco e análise de portfólio:** Associar previsões de preços com medidas de risco financeiro permitirá aplicações práticas em gestão de portfólio, estratégias de *hedge* e tomada de decisão automatizada, ampliando a relevância dos modelos no contexto financeiro real.

Referências

- Alpaydin, E. (2020). *Introduction to machine learning* (4^a ed.). MIT Press.
- Bai, S., Kolter, J. Z., & Koltun, V. (2018). An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv preprint arXiv:1803.01271*. <https://arxiv.org/abs/1803.01271>
- Bigaton, R. P., Botelho, J. P. M., Silva, G. C. d., Santos, M. G. C. d., Silva, P. H. N. C., & Pakes, P. R. (2025). O impacto das criptomoedas no mercado financeiro: um estudo multi-caso sobre desafios e oportunidades na economia global. *Revista de Gestão e Secretariado*, 16(3), e4802. <https://doi.org/10.7769/gesec.v16i3.4802>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Buterin, V. (2014). *A next-generation smart contract and decentralized application platform* (Whitepaper). Ethereum Foundation. <https://ethereum.org/en/whitepaper/>
- Chai, T., & Draxler, R. (2014). Root mean square error (RMSE) or mean absolute error (MAE)?–Arguments against avoiding RMSE in the literature. *Geoscientific Model Development*, 7, 1247–1250. <https://doi.org/10.5194/gmd-7-1247-2014>
- Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation. Em A. Moschitti, B. Pang & W. Daelemans (Eds.), *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)* (pp. 1724–1734). Association for Computational Linguistics. <https://doi.org/10.3115/v1/D14-1179>
- CoinMarketCap. (n.d.). *CoinMarketCap: Preços de criptomoedas, gráficos e dados de mercado* [Acesso em 25 de outubro de 2025].
- Consuledge. (2024). *Understanding GRU: A simpler alternative to LSTM*. Obtido outubro 26, 2025, de <https://consuledge.com.au/blog/understanding-gru-a-simpler-alternative-to-lstm/>

- Contributors, A. T. (2025). *tsaug: Python package for time series augmentation - Drift module* [Accessed: 2025-12-29]. https://tsaug.readthedocs.io/en/stable/_modules/tsaug/_augmenter/drift.html
- De Myttenaere, A., Golden, B., Le Grand, B., & Rossi, F. (2016). Mean absolute percentage error for regression models. *Neurocomputing*, 192, 38–48.
- Derbentsev, V., Datsenko, N., Babenko, V., Pushko, O., & Pursky, O. (2020–outubro 9). Forecasting cryptocurrency prices using ensembles-based machine learning approach. *2020 IEEE International Conference on Problems of Infocommunications, Science and Technology (PIC S&T)*, 707–712.
- Enholm, I. M., Papagiannidis, S., Mikalef, P., & Krogstie, J. (2022). Artificial Intelligence and Business Value: A Literature Review. *Information Systems Frontiers*, 24, 1709–1734. <https://doi.org/10.1007/s10796-021-10186-w>
- Fundação Getulio Vargas. (2014). *Bitcoin: A moeda na era digital*. FGV. <https://d3ptueit7w3f7j.cloudfront.net/Livros/Bitcoin+A+Moeda+na+Era+Digital.pdf>
- Ghosh, I., Alfaro-Cortés, E., Gámez, M., & García-Rubio, N. (2026). When Political Leaders Speak, Market Reacts: Unveiling the Dynamic Nexus of Media Chatter and Crypto Movements. *Borsa Istanbul Review*, 100786. <https://doi.org/10.1016/j.bir.2026.100786>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning* [<http://www.deeplearningbook.org>]. MIT Press.
- Govindan, K. (2022). Tunneling the barriers of blockchain technology in remanufacturing for achieving sustainable development goals: A circular manufacturing perspective. *Business Strategy and the Environment*, 31, 3769–3785. <https://doi.org/10.1002/bse.3031>
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9, 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- IBM. (2025). *O que é random forest?* Obtido outubro 26, 2025, de <https://www.ibm.com/br-pt/think/topics/random-forest>
- Iwana, B. K., & Uchida, S. (2021). An empirical survey of data augmentation for time series classification. *Pattern Recognition*, 112, 107789. <https://doi.org/10.1016/j.patcog.2020.107789>

KaNaung. (2024). *Understanding LSTM: A Deep Dive into its Inner Workings with Code Walkthrough* [Acesso em: 28 out. 2025]. <https://medium.com/@kanaung.academy/understanding-lstm-a-deep-dive-into-its-inner-workings-with-code-walkthrough-5337e4561e1b>

Karthisha, A., Chetan Kumar, G., Venkat Chowdary, C. G., Ojeshwar, S., & Reddy, S. R. P. (2025). Interactive Financial Dashboard with Predictive Analytics and Chatbot Assistance. Em J. K. Katiyar et al. (Eds.), *Proceedings of ICCSCE 2025* (pp. 77–84, Vol. 124). Atlantis Press.

Kriptomat. (s.d.). *Uma breve história das criptomoedas*. Obtido janeiro 20, 2026, de <https://kriptomat.io/pt/criptomoedas/uma-breve-historia-das-criptomoedas/>

Lee, J., Suh, T., Roy, D., Baucus, M., & Roy, P. (2019). Emerging technology and business model innovation: The case of artificial intelligence. *Journal of Open Innovation: Technology, Market, and Complexity*, 5(3), 44. <https://doi.org/https://doi.org/10.3390/joitmc5030044>

Lee, K., Ray, J., & Safta, C. (2021). *Figura 3. Convolutional neural network architecture for disease forecasting* [Figura extraída do artigo original publicado em *PLOS ONE*]. <https://doi.org/10.1371/journal.pone.0254319.g003>

Li, T. (2025). Prediction and analysis of Bitcoin prices using diverse regression models. *Proceedings of the 1st International Conference on E-commerce and Artificial Intelligence (ECAI 2024)*, 286–291. <https://doi.org/10.5220/0013215000003822>

McNally, S., Roche, J., & Caton, S. (2018–março 23). Predicting the price of Bitcoin using machine learning. *Proceedings of the 2018 26th Euromicro International Conference on Parallel, Distributed and Network-based Processing (PDP)*, 339–343. <https://doi.org/10.1109/PDP2018.2018.00060>

Mitchell, T. M. (1997). *Machine Learning* [<https://www.cs.cmu.edu/~tom/files/MachineLearningTomMitchell.pdf>]. McGraw-Hill.

Mittendorf, M., Nielsen, U., & Bingham, H. (2022). The Prediction of Sea State Parameters by Deep Learning Techniques using Ship Motion Data.

- Mostafaei, H., Kordnoori, S., Ostadrahimi, M., & Banihashemi, S. S. A. (2025). Applications of artificial intelligence in global diplomacy: A review of research and practical models. *Sustainable Futures*, 9, 100486. <https://doi.org/https://doi.org/10.1016/j.sftr.2025.100486>
- Nakamoto, S. (2008). *Bitcoin: A peer-to-peer electronic cash system*. <https://bitcoin.org/bitcoin.pdf>
- Nikitin, A. (2023, outubro). *Time series augmentations: A simple yet effective way to increase the amount of time series data* [Blog post]. Towards Data Science. <https://towardsdatascience.com/time-series-augmentations-16237134b29b>
- Normandin, J., Brunetti, J., Cadillac, N., Castaneda, M., Gelinas, K., McCormick, M., Modol, A., Reynolds, H., Almaraz, J., Guijarro, V., & Solinis, A. (2025). Understanding the impact of digital currencies: From private companies to central banks. *Journal for Global Business and Community*, 16(2). <https://doi.org/10.56020/001c.142902>
- Omole, O., & Enke, D. (2024). Deep learning for Bitcoin price direction prediction: models and trading strategies empirically compared. *Financial Innovation*, 10, 117. <https://doi.org/10.1186/s40854-024-00643-1>
- Patel, R., Singh, A., & Kumar, V. (2024). Cryptocurrency forecasting using deep learning models. *HighTech and Innovation Journal*, 5(3), 641–652. <https://doi.org/10.32734/hightechjournal.v5i3.641>
- Reiff, N. (s.d.). *Were There Cryptocurrencies Before Bitcoin?* Obtido janeiro 20, 2026, de <https://www.investopedia.com/tech/were-there-cryptocurrencies-bitcoin/>
- Russell, S. J., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach, Global Edition* (4^a ed.). Pearson Higher Education.
- Saadah, S., & Whafa, A. A. (2020–agosto 6). Monitoring financial stability based on prediction of cryptocurrencies price using intelligent algorithm. *Proceedings of the 2020 International Conference on Data Science and Its Applications (ICoDSA)*, 1–10.
- Sebastião, H., & Godinho, P. (2021). Forecasting and trading cryptocurrencies with machine learning under changing market conditions. *Financial Innovation*, 7(1), 1–30. <https://doi.org/10.1186/s40854-020-00217-x>

- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 5998–6008. <https://arxiv.org/abs/1706.03762>
- Wang, C., Chen, Y., Zhang, S., & Zhang, Q. (2022). Stock market index prediction using deep Transformer model. *Expert Systems with Applications*, 208, 118128. <https://doi.org/https://doi.org/10.1016/j.eswa.2022.118128>
- Wen, Q., Sun, L., Yang, F., Song, X., Gao, J., Wang, X., & Xu, H. (2020). Time Series Data Augmentation for Deep Learning: A Survey. *arXiv preprint arXiv:2002.12478*.
- Willmott, C., & Matsuura, K. (2005). Advantages of the Mean Absolute Error (MAE) over the Root Mean Square Error (RMSE) in Assessing Average Model Performance. *Climate Research*, 30, 79. <https://doi.org/10.3354/cr030079>
- Wright, S. (1921). Correlation and causation. *Journal of Agricultural Research*, 20(7), 557–585.
- Yakovenko, A. (2017). *Solana: A new architecture for a high performance blockchain*. <https://solana.com/solana-whitepaper.pdf>
- Yu, S. (2025). Prediction of DOGE based on random forest, long short-term memory and transformer. *Proceedings of the 1st International Conference on E-commerce and Artificial Intelligence (ECAI 2024)*, 188–194. <https://doi.org/10.5220/0013212500003822>
- Zheng, Z., Xie, S., Dai, H.-N., Chen, X., & Wang, H. (2018). Blockchain challenges and opportunities: A survey. *International Journal of Web and Grid Services*, 14(4), 352–375. <https://www.inderscience.com/info/inarticle.php?artid=95647>

